



Δημοκρίτειο Πανεπιστήμιο Θράκης
Πολυτεχνική Σχολή Ξάνθης
Τμήμα Ηλεκτρολόγων Μηχανικών & Μηχανικών Υπολογιστών
Τομέας Λογισμικού & Ανάπτυξης Εφαρμογών

Σχεδιασμός και αξιολόγηση συστημάτων Ομοσπονδιακής Μάθησης για την παραγωγή προτάσεων με βάση γράφους

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Ευστράτιος Πολίτης, ΑΕΜ: 58028

Επιβλέπων καθηγητής: Πάυλος Εφραιμίδης, Καθηγητής
Τμήμα ΗΜΜΥ, Δ.Π.Θ.

Ξάνθη, 2026



Δημοκρίτειο Πανεπιστήμιο Θράκης
Πολυτεχνική Σχολή Ξάνθης
Τμήμα Ηλεκτρολόγων Μηχανικών & Μηχανικών Υπολογιστών
Τομέας Λογισμικού & Ανάπτυξης Εφαρμογών

Σχεδιασμός και αξιολόγηση συστημάτων Ομοσπονδιακής Μάθησης για την παραγωγή προτάσεων με βάση γράφους

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Ευστράτιος Πολίτης, ΑΕΜ: 58028

ΕΞΕΤΑΣΤΙΚΗ ΕΠΙΤΡΟΠΗ

Επιβλέπων: Παύλος Εφραιμίδης, Καθηγητής, Τμήμα ΗΜΜΥ, Δ.Π.Θ.

2ο Μέλος: Ελευθερία Κατσίρη, Επίκουρη Καθηγήτρια, Τμήμα ΗΜΜΥ, Δ.Π.Θ.

3ο Μέλος: Ηλίας Θεοδωρακόπουλος, Επίκουρος Καθηγητής, Τμήμα ΗΜΜΥ, Δ.Π.Θ.

Ξάνθη, 2026



Democritus University of Thrace
Xanthi School of Engineering
Department of Electrical & Computer Engineering
Sector of Software & Application Development

Design and evaluation of Federated Learning systems for graph-based recommendation

DIPLOMA THESIS

Efstratios Politis, AEM: 58028

COMMITTEE OF EXAMINERS

- Supervisor:** Pavlos Efraimidis, Professor, Dept. of ECE, D.U.Th.
Member 2: Eleftheria Katsiri, Assistant Professor, Dept. of ECE, D.U.Th.
Member 3: Ilias Theodorakopoulos, Assistant Professor, Dept. of ECE, D.U.Th.

Xanthi, 2026

ΑΝΑΦΟΡΑ ΣΤΗΝ ΤΗΡΗΣΗ ΤΩΝ ΑΚΑΔΗΜΑΪΚΩΝ ΑΡΧΩΝ ΔΕΟΝΤΟΛΟΓΙΑΣ

Η παρούσα εργασία με τίτλο «Σχεδιασμός και Αξιολόγηση Συστημάτων Ομοσπονδιακής Μάθησης για την Παραγωγή Προτάσεων με Βάση Γράφους» είναι πρωτότυπη και πραγματοποιήθηκε από τον φοιτητή του Τμήματος Ηλεκτρολόγων Μηχανικών & Μηχανικών Η/Υ Ευστράτιο Πολίτη, με Αρ. Μητρώου ΑΕΜ ee58028, στο Εργαστήριο Προγραμματισμού και Επεξεργασίας Πληροφοριών του Τομέα Λογισμικού & Ανάπτυξης Εφαρμογών, υπό την επίβλεψη του Παύλου Εφραιμίδη. Η συγγραφή της εργασίας πραγματοποιήθηκε εξολοκλήρου από τον φοιτητή Ευστράτιο Πολίτη, υπό την καθοδήγηση και τις υποδείξεις του επιβλέποντά του.

Βεβαιώνεται ότι, κατά την εκπόνηση και τη συγγραφή της εργασίας, ο φοιτητής τηρήσε τα προβλεπόμενα από τον νόμο και τον αντίστοιχο εσωτερικό κανονισμό του Τμήματος, καθώς και ότι σεβάστηκε πλήρως τις Αρχές της Ακαδημαϊκής Ηθικής και του Κώδικα Δεοντολογίας, οι οποίες απαγορεύουν την παραποίηση των ερευνητικών / πειραματικών αποτελεσμάτων, την αναφορά ψευδών στοιχείων, την κατάχρηση της διανοητικής ιδιοκτησίας τρίτων και τη λογοκλοπή, και ότι η εργασία εκπονήθηκε με σεβασμό στις αρχές αυτές.

Εάνθη, 21 Αυγούστου 2026

Ευστράτιος Πολίτης

Περίληψη

Η ραγδαία εξάπλωση των συσκευών του Διαδικτύου των Πραγμάτων (IoT) έχει καταστήσει τη σύσταση αυτοματισμών (κανόνων της μορφής «αν συμβεί το A, τότε εκτέλεσε το B») ένα ολοένα και πιο σημαντικό πρόβλημα. Τα δεδομένα που απαιτούνται για την εκπαίδευση ενός τέτοιου συστήματος είναι όμως εξ ορισμού ευαίσθητα, γεγονός που καθιστά την κεντριοποιημένη συλλογή τους προβληματική. Η παρούσα εργασία μελετά το πρόβλημα της σύστασης κανόνων IoT σε ομοσπονδιακό πλαίσιο, ορμώμενη από τον ανοικτό διαγωνισμό της εταιρείας Wyze και τη λύση της δεύτερης θέσης.

Το πρόβλημα επαναδιατυπώνεται ως ομοσπονδιακή πρόβλεψη συνδέσεων σε γράφους ανά χρήστη και αναπτύσσονται τρεις διαδοχικές εκδόσεις μοντέλου αυξανόμενης πολυπλοκότητας, καταλήγοντας σε ένα relational μοντέλο που συνδυάζει τον CompGCN encoder, τον ComplEx decoder και τη συνάρτηση σφάλματος InfoNCE. Το μοντέλο αυτό βελτιώνει την κεντριοποιημένη λύση αναφοράς κατά 71% στη μετρική MRR. Η συστηματική αξιολόγηση σε τέσσερα σενάρια ενορχήστρωσης (κεντριοποιημένο, cross-silo και δύο παραλλαγές cross-device) αποκαλύπτει ότι η βέλτιστη επιλογή μοντέλου εξαρτάται από τον τύπο της ενορχήστρωσης: το ισχυρότερο μοντέλο κυριαρχεί παντού, εκτός από το πιο κατανεμημένο σενάριο, όπου μια απλούστερη έκδοση αποδεικνύεται ανθεκτικότερη.

Λέξεις-κλειδιά: Ομοσπονδιακή Μάθηση, Νευρωνικά Δίκτυα Γράφων, Συστήματα Σύστασης, Σύσταση Κανόνων, Διαδίκτυο των Πραγμάτων, Πρόβλεψη Συνδέσεων, Μη-IID Δεδομένα

Abstract

The rapid proliferation of Internet of Things (IoT) devices has made the recommendation of automations (rules of the form "if A happens, then perform B") an increasingly important problem. The data required to train such a system is, however, inherently sensitive, which makes its centralized collection problematic. This thesis studies the problem of IoT rule recommendation in a federated setting, taking as its starting point Wyze's open competition and the second-place solution as a reference baseline.

The problem is reformulated as federated link prediction over per-user graphs, and three successive model versions of increasing complexity are developed, culminating in a relational model that combines a CompGCN encoder, a ComplEx decoder, and an InfoNCE loss. This model improves upon the centralized reference solution by 71% in Mean Reciprocal Rank (MRR). A systematic evaluation across four orchestration scenarios (centralized, cross-silo, and two cross-device variants) reveals that the optimal model choice depends on the type of orchestration: the strongest model dominates everywhere except the most distributed scenario, where a simpler version proves more robust.

Keywords: Federated Learning, Graph Neural Networks, Recommender System, Rule Recommendation, Internet of Things, Link Prediction, Non-IID Data

Ευχαριστίες

Η παρούσα εργασία είναι αποτέλεσμα πολύωρων προσπαθειών και απόδειξη της λήξης ενός μακρού κύκλου σπουδών. Δεν θα μπορούσε να έχει επιτευχθεί χωρίς την συμβολή και την υποστήριξη μίας ομάδας ανθρώπων, τους οποίους θα ήθελα να ευχαριστήσω.

Η εκπόνηση της διπλωματικής μου εργασίας υποστηρίχθηκε από τον επιβλέποντα καθηγητή κ. Παύλο Εφραιμίδη και τον υποψήφιο διδάκτορα Νικόλαο Παυλίδη, οι οποίοι αποτέλεσαν στέρεο ακαδημαϊκό στήριγμα και εξασφάλισαν όλα τα απαραίτητα μέσα για την ολοκλήρωσή της. Η συνεισφορά τους στην οργάνωση και την δόμηση της εργασίας, η επιστημονική τους καθοδήγηση και η εμπιστοσύνη τους ήταν κομβικής σημασίας σε ολόκληρη την διαδικασία, από την σύλληψη και την εισαγωγή της ιδέας μέχρι το πειραματικό στάδιο και την συγγραφή του τελικού παραδοτέου.

Αναγνώριση ωστόσο αξίζει και στους ανθρώπους που είχα κοντά μου καθ' όλη την διάρκεια του ακαδημαϊκού μου ταξιδιού. Ευχαριστώ από καρδιάς τους υπέροχους φίλους που απέκτησα αυτά τα χρόνια, με τους οποίους μοιράστηκα τις ανησυχίες μου, το άγχος μου, αλλά και όλες τις στιγμές που μας έφεραν κοντά και μας έκαναν να γελάμε δυνατά. Χωρίς την αγκαλιά τους δεν θα μπορούσα να βρίσκομαι σήμερα εδώ. Θα ήθελα επίσης να ευχαριστήσω τους γονείς μου για το διαρκές και ειλικρινές τους ενδιαφέρον για την δουλειά μου σε όλη την πορεία των σπουδών μου.

Ιδιαίτερη αναφορά οφείλεται και στην open-source κοινότητα, η οποία καθημερινά προσφέρει εργαλεία απαραίτητα τόσο για την εκπόνηση της παρούσας εργασίας όσο και για κάθε πτυχή της ψηφιακής ζωής, αμερόληπτα και αφιλοκερδώς. Η ακαδημαϊκή και επιστημονική κοινότητα οφείλει μεγάλο μέρος της προόδου της στην ανοιχτή και δωρεάν τεχνολογία.

Στην Αναστασία και στο Μάνγκο

Περιεχόμενα

1	Εισαγωγή	1
1.1	Κίνητρο	1
1.2	Αντικείμενο και στόχοι	2
1.3	Related work	3
1.4	Δομή της εργασίας	3
2	Θεωρητικό υπόβαθρο	4
2.1	Εισαγωγή στην Μηχανική Μάθηση	4
2.1.1	Μηχανική Μάθηση	4
2.1.2	Νευρωνικά Δίκτυα	5
2.1.3	Η διαδικασία εκπαίδευσης	6
2.2	Εισαγωγή στην Ομοσπονδιακή Μάθηση	7
2.2.1	Εισαγωγή στο IoT	7
2.2.2	Ομοσπονδιακή Μάθηση	8
2.3	Εισαγωγή στην Θεωρία Γράφων	12
2.4	Graph Neural Networks (GNNs)	14
2.5	Συστήματα Σύστασης	17
3	Περιγραφή του προβλήματος	20
3.1	Ο διαγωνισμός της Wyze: κίνητρα και δεδομένα	20
3.2	Μοντελοποίηση του προβλήματος	21
3.3	Διαχείριση δεδομένων	23
3.4	Το αρχικό μοντέλο της Wyze	25
3.4.1	Το pipeline του μοντέλου	25
3.4.2	Οι αδυναμίες του μοντέλου	28
3.5	Η δεύτερη θέση του διαγωνισμού	28
4	Μεθοδολογία	31
4.1	Επισκόπηση του συστήματος	31
4.1.1	Στόχος της υλοποίησης	31
4.1.2	Ανάπτυξη των μοντέλων	31
4.1.3	Δομή του κώδικα	32
4.2	Πρώτη έκδοση (v1)	33
4.2.1	Προεπεξεργασία δεδομένων	33
4.2.2	Μοντέλα μηχανικής μάθησης	36
4.2.3	Ενορχήστρωση	36

4.3	Δεύτερη έκδοση (v2)	37
4.4	Τρίτη έκδοση (v3)	39
4.4.1	CompGCN encoder	39
4.4.2	ComplEx decoder	40
4.4.3	InfoNCE loss και hard negative sampling	41
5	Πειράματα	47
5.1	Τεχνικές προδιαγραφές και εργαλεία	47
5.1.1	Απαιτήσεις συστήματος	47
5.1.2	Βιβλιοθήκες και εργαλεία	47
5.2	Ανάλυση δεδομένων	48
5.2.1	Αρχικά δεδομένα	48
5.2.2	Λεξιλόγιο	49
5.2.3	Φιλτράρισμα και επαναφορά «φαντασμάτων»	49
5.2.4	Data splits και sampling	50
5.2.5	Κατανομές	51
5.3	Τύποι ενορχήστρωσης	53
5.4	Μετρικές και πρωτόκολλα αξιολόγησης	55
5.4.1	Μετρικές	55
5.4.2	Πρωτόκολλα αξιολόγησης	55
5.5	Αποτελέσματα	56
5.5.1	Καμπύλες σύγκλισης	58
5.5.2	Ablation studies	64
6	Συμπεράσματα	68
6.1	Σύνοψη	68
6.2	Βασικά συμπεράσματα	68
6.3	Περιορισμοί	69
6.4	Μελλοντικές επεκτάσεις	70
	Βιβλιογραφία	71

Κατάλογος σχημάτων

2.1	Θεμελιώδη προβλήματα μηχανικής μάθησης	5
2.2	Βασική δομή MLP	6
2.3	Centralized vs. Federated Learning.....	9
2.4	Pipeline ομοσπονδιακής μάθησης	10
2.5	Client drift.....	11
2.6	Cross-silo FL vs. cross-device FL	12
2.7	Παραδείγματα γράφων	13
2.8	Γράφος με τύπους ακμών και κόμβων	14
2.9	Γενική δομή GNN	15
2.10	Message passing στα GNNs	16
2.11	Το pipeline του GraphSAGE	17
2.12	Χρήση GNN για πρόβλεψη	18
2.13	Συστήματα σύστασης	18
3.1	Η τριπλέτα συσκευή–κανόνας–συσκευή.....	21
3.2	User-item matrix vs. γράφος	23
3.3	Η αρχιτεκτονική του FedRule	26
4.1	Παράδειγμα γράφου χρήστη	35
4.2	Pipeline πρώτης έκδοσης	36
4.3	Pseudo-embeddings της v2	38
4.4	Pipeline δεύτερης έκδοσης	39
4.5	Multi-relational γράφος	40
4.6	Αρχιτεκτονική CompGCN	41
4.7	Αρχιτεκτονική ComplEx	42
4.10	Pipeline τρίτης έκδοσης.....	43
4.8	Hard negatives	44
4.9	InfoNCE loss	45
4.11	Συνολική αρχιτεκτονική της τελικής υλοποίησης	46
5.1	Διαδικασία φιλτραρίσματος δεδομένων	50
5.2	Κατανομές συσκευών και κανόνων ανά χρήστη	52
5.3	Σενάρια ενορχήστρωσης	54
5.4	Σύγκλιση v1/v2/v3 — centralized.....	59
5.5	Σύγκλιση v1/v2/v3 — cross-silo	60
5.6	Σύγκλιση v1/v2/v3 — pseudo-cross-device	61

5.7	Σύγκλιση v1/v2/v3 — true cross-device	62
5.8	Σύγκλιση της v3 στα τέσσερα σενάρια	63
5.9	DistMult vs. ComplEx	66

Κατάλογος πινάκων

4.1	Απόσπασμα του συνόλου δεδομένων <code>train_device.csv</code>	34
4.2	Απόσπασμα του συνόλου δεδομένων <code>train_rules.csv</code>	35
5.1	Μέγεθος ακατέργαστων δεδομένων	48
5.2	Επίδραση της επαναφοράς «φαντασμάτων»	50
5.3	Κατανομές συσκευών και κανόνων ανά χρήστη	51
5.4	Σενάρια εννοχρήστρωσης	54
5.5	Συγκεντρωτικός πίνακας αποτελεσμάτων	57
5.6	Ablation studies	64
5.7	Συνεισφορά του CompGCN	67

Κεφάλαιο 1

Εισαγωγή

1.1 Κίνητρο

Το Διαδίκτυο των Πραγμάτων (Internet of Things, IoT) είναι μία από τις πλέον διαδεδομένες εμπορικές τεχνολογίες σήμερα. Πρόκειται για ένα οικοσύστημα διασυνδεδεμένων «έξυπνων» συσκευών (λαμπτήρων, καμερών, θερμοστατών, αισθητήρων κ.ά.) που έχουν την δυνατότητα να αυτοματοποιούνται με βάση τις ανάγκες και τις συνήθειες κάθε χρήστη, επιτελώντας έναν προσωποποιημένο σκοπό. Η αυτοματοποίηση αυτή γίνεται μέσω κανόνων της μορφής «αν η κάμερα εντοπίσει κίνηση, τότε άναψε το φως», οι οποίοι μετατρέπουν τις συμβατικές συσκευές σε ένα συνεκτικό, έξυπνο περιβάλλον. Ωστόσο, η δημιουργία τέτοιων κανόνων παραμένει μια χειροκίνητη διαδικασία, την οποία πολλοί χρήστες δεν ολοκληρώνουν ποτέ, με αποτέλεσμα να μην αξιοποιείται το σημαντικό πλεονέκτημα των έξυπνων συσκευών έναντι των συμβατικών.

Το πρόβλημα αυτό αποτελεί αντικείμενο των συστημάτων σύστασης (recommender systems), μεθόδων που έχουν την δυνατότητα να προτείνουν προσωποποιημένους κανόνες σε κάθε χρήστη, αναλύοντας στατιστικά τις υπάρχουσες προτιμήσεις του ίδιου, καθώς και του συνόλου των χρηστών. Ωστόσο, η εκπαίδευση ενός τέτοιου συστήματος απαιτεί δεδομένα εξ ορισμού ευαίσθητα: η λίστα των συσκευών ενός σπιτιού και οι αυτοματισμοί του αποκαλύπτουν το ωράριο, τις συνήθειες και την τοποθεσία των χρηστών. Η συλλογή αυτών των δεδομένων και η εκπαίδευση ενός μοντέλου σε έναν κεντρικό server (η κλασική δηλαδή προσέγγιση της Μηχανικής Μάθησης) εγείρει σοβαρούς κινδύνους για την ιδιωτικότητα των χρηστών. Η Ομοσπονδιακή Μάθηση (Federated Learning) προσφέρει μια εναλλακτική: την εκπαίδευση ενός μοντέλου απευθείας στην συσκευή κάθε χρήστη, χωρίς τα δεδομένα καθαυτά να εγκαταλείπουν την συσκευή [1]. Το σημείο σύνδεσης της σύστασης κανόνων IoT με την ομοσπονδιακή μάθηση αποτελεί το κεντρικό αντικείμενο της παρούσας εργασίας.

1.2 Αντικείμενο και στόχοι

Αφορμή για την εργασία αποτέλεσε ο ανοιχτός διαγωνισμός σύστασης κανόνων της εταιρείας Wyze [2], ο οποίος δημοσιοποίησε ένα εκτενές, πραγματικό σύνολο δεδομένων από συσκευές και κανόνες εκατοντάδων χιλιάδων χρηστών. Η λύση της δεύτερης θέσης του διαγωνισμού [3], που χρησιμοποιείται εδώ ως σημείο αναφοράς, αντιμετωπίζει το πρόβλημα ως μια centralized πρόβλεψη συνδέσεων σε γράφους. Παρότι πετυχαίνει ισχυρές επιδόσεις, αγνοεί εντελώς το πρόβλημα της ιδιωτικότητας που καθιστά το πρόβλημα ενδιαφέρον σε ρεαλιστικές συνθήκες.

Στόχος της παρούσας εργασίας είναι να επαναδιατυπώσει το πρόβλημα σε federated πλαίσιο και να απαντήσει σε δύο ερωτήματα: (α) μπορεί ένα μοντέλο εκπαιδευμένο ομοσπονδιακά να προσεγγίσει ή και να ξεπεράσει την centralized λύση αναφοράς; και (β) πώς μεταβάλλεται η επίδοση ανάλογα με τον τύπο της ενορχήστρωσης: από την centralized εκπαίδευση, στη συνεργασία λίγων οργανισμών (cross-silo), έως το ρεαλιστικό σενάριο εκατομμυρίων μεμονωμένων συσκευών (cross-device);

Οι κύριες συνεισφορές της εργασίας είναι οι εξής:

- Επαναδιατύπωση της σύστασης κανόνων IoT ως ομοσπονδιακό task, με μια ενιαία υλοποίηση που εκτελείται αυτούσια σε όλους τους τύπους ενορχήστρωσης.
- Τρεις εκδόσεις μοντέλου αυξανόμενης πολυπλοκότητας, με την τελευταία (CompGCN + ComplEx + InfoNCE) να βελτιώνει την centralized λύση αναφοράς κατά 71% στη μετρική MRR.
- Μελέτη της επίδοσης του συστήματος σε τέσσερα σενάρια ενορχήστρωσης, η οποία καταδεικνύει ότι η βέλτιστη επιλογή μοντέλου εξαρτάται από τον τύπο της ενορχήστρωσης: το ισχυρότερο μοντέλο κυριαρχεί παντού εκτός από το πιο καταναεμημένο σενάριο, όπου ένα απλούστερο μοντέλο αποδεικνύεται καλύτερο.
- Ένα αυστηρό πρωτόκολλο αξιολόγησης cold-start με πλήρη leave-one-out μηχανισμό, που μετράει την πραγματική ικανότητα γενίκευσης σε άγνωστους χρήστες, πέρα από τη μετρική του διαγωνισμού.

1.3 Related work

Η παρούσα εργασία στηρίζεται στην δημοσίευση της Wyze που συνόδευε τον διαγωνισμό [4, 5], η οποία εισάγει ένα σύστημα σύστασης κανόνων IoT βασισμένο σε federated GNNs. Το μοντέλο της Wyze μοντελοποιεί κάθε χρήστη ως έναν γράφο συσκευών και κανόνων και εκπαιδεύει ομοσπονδιακά ένα GNN για πρόβλεψη συνδέσεων. Η παρούσα διπλωματική μοιράζεται αυτή την δομή, αλλά την εμπλουτίζει, μελετώντας διαφοροποιήσεις στην απόδοση ανάλογα με το περιβάλλον federation, και εισάγει μια νέα relational αρχιτεκτονική για την βελτιστοποίηση του συστήματος.

Ευρύτερα, η εργασία απασχολεί τρία ερευνητικά πεδία: τα συστήματα σύστασης, την ομοσπονδιακή μάθηση και την βαθιά μάθηση σε γράφους, καθένα από τα οποία αναπτύσσεται στο [Κεφάλαιο 2](#). Το ίδιο το πρόβλημα, ο διαγωνισμός της Wyze και η λύση αναφοράς περιγράφονται αναλυτικά στο [Κεφάλαιο 3](#).

1.4 Δομή της εργασίας

Η εργασία οργανώνεται ως εξής: Το [Κεφάλαιο 2](#) παρουσιάζει το θεωρητικό υπόβαθρο: Μηχανική Μάθηση, Ομοσπονδιακή Μάθηση, θεωρία γράφων, GNNs και συστήματα σύστασης. Το [Κεφάλαιο 3](#) περιγράφει το πρόβλημα, τον διαγωνισμό της Wyze, τη μοντελοποίηση των δεδομένων ως γράφων και την λύση της δεύτερης θέσης. Το [Κεφάλαιο 4](#) αναπτύσσει τη μεθοδολογία και τις τρεις εκδόσεις μοντέλου. Το [Κεφάλαιο 5](#) παρουσιάζει την πειραματική διάταξη, την ανάλυση των δεδομένων, τα σενάρια ενορχήστρωσης, το πρωτόκολλο αξιολόγησης και τα αποτελέσματα. Τέλος, το [Κεφάλαιο 6](#) συνοψίζει τα συμπεράσματα, συζητά τους περιορισμούς και προτείνει μελλοντικές επεκτάσεις.

Κεφάλαιο 2

Θεωρητικό υπόβαθρο

2.1 Εισαγωγή στην Μηχανική Μάθηση

2.1.1 Μηχανική Μάθηση

Η Μηχανική Μάθηση (Machine Learning, ML) είναι ένα ερευνητικό πεδίο της Τεχνητής Νοημοσύνης που εστιάζει στην ανάπτυξη αλγορίθμων και μοντέλων που έχουν την ικανότητα να εξαγάγουν γνώση από σύνολα δεδομένων και να την εφαρμόζουν σε νέες, άγνωστες εισόδους, χωρίς να απαιτούν ρητό προγραμματισμό για κάθε ενέργεια [6, 7]. Για να επιτευχθεί αυτό, αξιοποιούνται διάφορες στατιστικές μέθοδοι αναγνώρισης και εξαγωγής προτύπων. Η θεμελιώδης διαφορά της Μηχανικής Μάθησης από τον κλασικό προγραμματισμό έγκειται στην αρχιτεκτονική της: αντί να χρησιμοποιηθούν αυστηροί ντετερμινιστικοί κανόνες if-then και αναλυτικοί υπολογισμοί, αναπτύσσονται στοχαστικά μοντέλα τα οποία αφομοιώνουν πληροφορία από μεγάλο όγκο δεδομένων μέσω μιας διαδικασίας που ονομάζεται «εκπαίδευση» (training) και εκφράζουν τα αποτελέσματα της ανάλυσής τους πιθανοκρατικά.

Κάποια από τα κλασικά προβλήματα που επιλύουν μοντέλα Μηχανικής Μάθησης είναι αυτά της ταξινόμησης (classification), του διαχωρισμού δηλαδή των δεδομένων σε δύο ή περισσότερες κλάσεις βάσει των χαρακτηριστικών τους, της στατιστικής παλινδρόμησης (regression), όπου μελετάται η συσχέτιση μίας εξαρτημένης τυχαίας μεταβλητής με μία ή περισσότερες ανεξάρτητες, και της μείωσης διαστατικότητας (dimensionality reduction), η οποία στοχεύει στην έκφραση δεδομένων από έναν χώρο πολλών διαστάσεων σε έναν μικρότερο, διατηρώντας όσο το δυνατόν περισσότερα από τα αρχικά τους χαρακτηριστικά [8, 9].

Οι μέθοδοι Μηχανικής Μάθησης διακρίνονται σε τρεις γενικές κατηγορίες: την επιτηρούμενη ή επιβλεπόμενη μάθηση (supervised learning), όπου τα επιθυμητά αποτελέσματα εξόδου (ετικέτες) δίνονται εκ των προτέρων στο πρόγραμμα με στόχο να αντιστοιχηθούν μέσω κάποιου κανόνα με τα δεδομένα εισόδου, την μη επιτηρούμενη ή μη επιβλεπόμενη μάθηση (unsupervised learning), στην οποία το πρόγραμμα καλεί-

ται να ανακαλύψει κρυφά μοτίβα από τα δεδομένα χωρίς να του δοθούν ενδεικτικά αποτελέσματα, και την ενισχυτική μάθηση (reinforcement learning), στην οποία το πρόγραμμα εξερευνά δυναμικά τον χώρο του προβλήματος και δέχεται σήματα επιβράβευσης ή ποινής ανάλογα με το πόσο κοντά βρίσκεται στον στόχο του [6, 8].




Σχήμα 2.1: Τρία θεμελιώδη προβλήματα μηχανικής μάθησης: η ταξινόμηση (classification) και η παλινδρόμηση (regression), που αποτελούν επιβλεπόμενα tasks, και η ομαδοποίηση (clustering), ένα μη επιβλεπόμενο task.

2.1.2 Νευρωνικά Δίκτυα

Μία από τις παλαιότερες αλλά και πλέον διαδεδομένες αρχιτεκτονικές της Μηχανικής Μάθησης είναι τα Τεχνητά Νευρωνικά Δίκτυα, ή απλώς Νευρωνικά Δίκτυα (Neural Networks, NNs). Εισήχθησαν το 1943 από τους McCulloch και Pitts, στην προσπάθειά τους να προσομοιώσουν μαθηματικά τους βιολογικούς νευρώνες του εγκεφάλου [10], ενώ αναπτύχθηκαν περαιτέρω το 1958 από τον Rosenblatt με την εισαγωγή του perceptron [11].

Ένα Νευρωνικό Δίκτυο απαρτίζεται από υπολογιστικούς κόμβους (νευρώνες), συνδεδεμένους μεταξύ τους και οργανωμένους σε επίπεδα (layers). Η βασική αρχιτεκτονική περιλαμβάνει ένα επίπεδο εισόδου, ένα επίπεδο εξόδου, και ένα ή περισσότερα ενδιάμεσα (κρυφά) επίπεδα ανάμεσά τους, στα οποία συντελείται η επεξεργασία της πληροφορίας (Σχήμα 2.2). Η είσοδος κάθε νευρώνα προκύπτει από τις εξόδους των νευρώνων του προηγούμενου επιπέδου με τους οποίους συνδέεται. Οι τιμές αυτές πολλαπλασιάζονται με κατάλληλους συντελεστές βάρους (weights), αθροίζονται, και το αποτέλεσμα διέρχεται από μία μη γραμμική συνάρτηση ενεργοποίησης, η οποία καθορίζει το τελικό σήμα εξόδου του νευρώνα [12].



Σχήμα 2.2: Η βασική δομή ενός πλήρως συνδεδεμένου νευρωνικού δικτύου (MLP): επίπεδο εισόδου, κρυφά επίπεδα και επίπεδο εξόδου. Στο συγκεκριμένο παράδειγμα φαίνεται ένα κρυφό επίπεδο.

Οι εφαρμογές των Νευρωνικών Δικτύων είναι ποικίλες, εκτεινόμενες από την επεξεργασία εικόνας και την πρόβλεψη χρονοσειρών, μέχρι τα συστήματα σύστασης (recommender systems) [13], με τα οποία καταπιάνεται η παρούσα διπλωματική εργασία.

2.1.3 Η διαδικασία εκπαίδευσης

Η εκπαίδευση των Νευρωνικών Δικτύων στηρίζεται σε μία επαναληπτική διαδικασία μαθηματικής βελτιστοποίησης. Προκειμένου το μοντέλο να αξιολογήσει την απόδοσή του, ορίζεται μία συνάρτηση σφάλματος (loss function), η οποία ποσοτικοποιεί την απόκλιση μεταξύ της τρέχουσας πρόβλεψης του δικτύου και του πραγματικού επιθυμητού αποτελέσματος. Στην αρχή της εκπαίδευσης, οι παράμετροι (βάρη) του μοντέλου αρχικοποιούνται με τυχαίες τιμές, οδηγώντας σε σχεδόν τυχαίες προβλέψεις και, επομένως, σε υψηλό σφάλμα. Σε κάθε επόμενο γύρο εκπαίδευσης, το μοντέλο υπολογίζει την κλίση (gradient) της συνάρτησης σφάλματος ως προς κάθε βάρος. Οι κλίσεις αυτές υποδεικνύουν την κατεύθυνση προς την οποία πρέπει να αναπροσαρμοστούν τα βάρη ώστε το σφάλμα να ελαχιστοποιηθεί. Το πόσο μεγάλη θα είναι η αναπροσαρμογή αυτή καθορίζεται από μία υπερπαράμετρο της εκπαίδευσης,

τον ρυθμό μάθησης (learning rate). Η επαναληπτική αυτή διαδικασία είναι ευρέως γνωστή ως Gradient Descent [6]. Με σωστή επιλογή παραμέτρων εκπαίδευσης και ικανό αριθμό επαναλήψεων, η διαδικασία συγκλίνει, με αποτέλεσμα το μοντέλο να μάθει τα λανθάνοντα μοτίβα των δεδομένων.

Η πιο συνηθής μέθοδος οργάνωσης και ενορχήστρωσης αυτής της διαδικασίας είναι η κεντρικοποιημένη (centralized learning), στην οποία όλα τα δεδομένα προς εκπαίδευση συγκεντρώνονται σε έναν κεντρικό διακομιστή (server), από όπου και τροφοδοτούνται στο μοντέλο. Αυτή η μέθοδος είναι υπολογιστικά αποδοτική, αφενός επειδή το μοντέλο εκπαιδεύεται στο πλήρες, πληροφοριακά πυκνό σύνολο δεδομένων, και αφετέρου γιατί δεν χρειάζονται επιπλέον επίπεδα επικοινωνίας για την ανανέωση και την μετάδοση των βαρών του. Ωστόσο, αυτή η απλότητα έρχεται με ένα κόστος. Η συγκέντρωση μεγάλου όγκου δεδομένων σε έναν κόμβο δημιουργεί ένα εξαιρετικά ευάλωτο σημείο αποτυχίας. Μία πιθανή κακόβουλη επίθεση στον κεντρικό διακομιστή αρκεί για να παραβιαστούν τα προσωπικά δεδομένα χιλιάδων χρηστών [14], γεγονός που καθιστά την κεντρικοποιημένη αρχιτεκτονική ακατάλληλη για εφαρμογές που πραγματεύονται ευαίσθητα προσωπικά δεδομένα, όπως ιατρικό ιστορικό ή τραπεζικούς λογαριασμούς.

2.2 Εισαγωγή στην Ομοσπονδιακή Μάθηση

2.2.1 Εισαγωγή στο IoT

Το Διαδίκτυο των Πραγμάτων (Internet of Things, IoT) είναι ένας από τους ταχύτερα αναπτυσσόμενους τομείς εμπορικά διαθέσιμων τεχνολογιών στις μέρες μας. Αφορά την ανάπτυξη «έξυπνων» συσκευών οικιακής χρήσης όπως λαμπτήρες, κάμερες ασφαλείας, θερμοστάτες, πρίζες κτλ, οι οποίες επικοινωνούν μεταξύ τους μέσω του διαδικτύου, καθιστώντας έτσι δυνατή την αυτοματοποίησή τους [15]. Για παράδειγμα, μία έξυπνη κάμερα ασφαλείας μπορεί να ειδοποιήσει τον χρήστη στο κινητό του όταν εντοπίσει κάποιο πρόσωπο στην είσοδο, ή μία προγραμματισμένη έξυπνη πρίζα μπορεί να ενεργοποιήσει τη θέρμανση λίγο πριν γυρίσει ο χρήστης στο σπίτι.

Όπως γίνεται αντιληπτό, η λειτουργία τέτοιων αυτοματισμών αντλεί ευαίσθητα προσωπικά δεδομένα χρηστών, όπως το ωράριο εργασίας τους, την τοποθεσία τους ή τα βιομετρικά τους χαρακτηριστικά. Επιπλέον, συνήθως απαιτείται ταυτοποίηση του χρήστη μέσω email ή αριθμού τηλεφώνου, καθώς και παραχώρηση πρόσβασης στο τοπικό του δίκτυο, πληροφορίες εξίσου ευαίσθητες. Η προσπάθεια κεντρικοποιημέ-


νης επεξεργασίας αυτών των δεδομένων για την εκπαίδευση μοντέλων Μηχανικής Μάθησης εγείρει προφανείς κινδύνους ασφαλείας. Για τον λόγο αυτό εισάγεται ένας νέος τρόπος εκπαίδευσης μοντέλων Μηχανικής Μάθησης, η Ομοσπονδιακή Μάθηση.

2.2.2 Ομοσπονδιακή Μάθηση

Η βασική αρχή της Ομοσπονδιακής Μάθησης (Federated Learning, FL), έγκειται στο γεγονός ότι τα προσωπικά δεδομένα κάθε χρήστη παραμένουν αποκλειστικά στην διάθεσή του. Για να επιτευχθεί αυτός ο στόχος, αντί να μεταφερθούν τα δεδομένα των χρηστών σε έναν κεντρικό υπολογιστή για την εκπαίδευση του μοντέλου, μεταφέρεται το μοντέλο στην συσκευή κάθε χρήστη, όπου εκπαιδεύεται τοπικά, χωρίς να διαμοιραστεί τα δεδομένα του [1]. Ο κεντρικός server λαμβάνει και αποθηκεύει αποκλειστικά τις παραμέτρους (βάρη) του δικτύου, οι οποίες αποτελούν ανώνυμες αριθμητικές μεταβλητές που δεν περιέχουν καμία πληροφορία για τους χρήστες.

Η αρχιτεκτονική της εκπαίδευσης χωρίζεται σε δύο οντότητες: τον κεντρικό διακομιστή (server), υπεύθυνο για την εντοπιστική της διαδικασίας και την αποθήκευση ενός κεντρικού, καθολικού μοντέλου (global model), και τους χρήστες/πελάτες (clients), οι οποίοι διαθέτουν τα τοπικά τους προσωπικά δεδομένα, και εκπαιδεύουν τα δικά τους τοπικά μοντέλα (local models), τα βάρη των οποίων συναθροίζονται για να απαρτίσουν το κεντρικό μοντέλο (Σχήμα 2.3) [16].


Η διαδικασία της εκπαίδευσης παρουσιάζει κάποιες διαφορές σε σχέση με την κλασική centralized υλοποίηση, μιας και πλέον αξιοποιείται η συσκευή κάθε χρήστη. Η εκπαίδευση εκτυλίσσεται σε γύρους επικοινωνίας (communication rounds) [17]. Αρχικά, ο server μεταδίδει το τρέχον καθολικό μοντέλο σε μέρος (ή στην πληρότητα) των clients προς εκπαίδευση. Ο κάθε client εκπαιδεύει το μοντέλο τοπικά, όχι στο σύνολο των δεδομένων όλων των χρηστών (καθώς δεν έχει πρόσβαση σε αυτά), αλλά αποκλειστικά στα δικά του, τοπικά δεδομένα. Όπως και στην centralized εκπαίδευση, ο κάθε client πραγματοποιεί gradient descent (βλ. Ενότητα 2.1.3). Ανάλογα με την φύση του προβλήματος προς επίλυση, μπορεί ο κάθε client να εκτελέσει έναν ή περισσότερους τέτοιους γύρους τοπικής εκπαίδευσης. Αφού κάθε client έχει ολοκληρώσει αυτό το στάδιο, αποστέλλει τα ανανεωμένα βάρη του μοντέλου (ή τις διαφορές τους) πίσω στον server. Ο server, με τη σειρά του, χρησιμοποιεί μια συνάρτηση συναθροίσης (aggregation function) για να συγχωνεύσει τις τοπικές ενημερώσεις σε ένα νέο, βελτιωμένο καθολικό μοντέλο. Η συνάρτηση αυτή μπορεί να έχει οποιαδήποτε μορφή κατά περίπτωση, αλλά συνήθως χρησιμοποιείται ο σταθμισμένος μέσος όρος (Federated Averaging, FedAvg) [1]. Σε αυτό το σημείο ολοκληρώνεται ένας γύρος επι-



Σχήμα 2.3: Σύγκριση κεντριοποιημένης (αριστερά) και ομοσπονδιακής (δεξιά) μάθησης: στην πρώτη τα δεδομένα συγκεντρώνονται στον server, ο οποίος εκπαιδεύει ένα κεντρικό μοντέλο, ενώ στη δεύτερη οι clients αποστέλλουν μόνο τα βάρη των τοπικών τους μοντέλων και ποτέ τα ίδια τους τα δεδομένα.


κοινωνίας και ξεκινάει ο επόμενος. Ο server στέλνει τα νέα, μεσοσταθμισμένα βάρη του μοντέλου στους clients, εκείνοι πραγματοποιούν κάποιους γύρους τοπικής εκπαίδευσης, αποστέλλουν πίσω τα νέα τους βάρη και ο server τα συναθροίζει. Μετά από κάποιον αριθμό επαναλήψεων, το μοντέλο συγκλίνει σε μία λύση που εκφράζει όλους τους clients σε κάποιο βαθμό, χωρίς να έχει εκπαιδευτεί ποτέ στο σύνολο των δεδομένων τους αυτούσιο. Τα στάδια της διαδικασίας απεικονίζονται στο [Σχήμα 2.4](#).

Αυτή η ιδιότητα ωστόσο της federated αρχιτεκτονικής εισάγει ένα θεμελιώδες πρόβλημα: τα δεδομένα των χρηστών είναι στατιστικά ετερογενή [18]. Σε αντίθεση με τις κεντριοποιημένες βάσεις δεδομένων, τα δεδομένα των αυτόνομων clients δεν είναι Ανεξάρτητα και Ταυτόσημα Κατανεμημένα (Independent and Identically Distributed, IID), δηλαδή δεν είναι ισορροπημένα ούτε ως προς τον όγκο ούτε ως προς την φύση της πληροφορίας που περιέχουν. Για παράδειγμα, το ιατρικό ιστορικό σε μία ορθοπεδική κλινική αποτελείται κυρίως από ορθοπεδικά περιστατικά, ενώ σε ένα γενικό νοσοκομείο υπάρχει σαφώς μεγαλύτερη γκάμα παθήσεων, και σαφώς περισσότερα περιστατικά συνολικά. Λόγω αυτής της στατιστικής ανισορροπίας, τα τοπικά μοντέλα τείνουν να συγκλίνουν προς εντελώς διαφορετικές, τοπικά βέλτιστες κατευθύνσεις. Όταν ο server επιχειρεί να αθροίσει αυτές τις αποκλίνουσες παραμέτρους, το καθολικό μοντέλο παρουσιάζει αστάθεια και συχνά αδυνατεί να συγκλί-



Σχήμα 2.4: Το pipeline ενός γύρου επικοινωνίας: **(α) πάνω αριστερά:** ο server μεταδίδει το global μοντέλο στους clients, **(β) πάνω δεξιά:** οι clients εκπαιδεύουν τοπικά τα μοντέλα τους, **(γ) κάτω δεξιά:** τα ανανεωμένα βάρη αποστέλλονται πίσω στον server, **(δ) κάτω αριστερά:** ο server κάνει aggregate τα βάρη στο global μοντέλο.


νει. Το φαινόμενο αυτό αναφέρεται στην βιβλιογραφία ως *client drift* (Σχήμα 2.5) [19, 18] και αντιμετωπίζεται με διάφορες αλγοριθμικές τεχνικές, οι οποίες θα αναλυθούν εκτενέστερα στην Ενότητα 3.3.



Σχήμα 2.5: Client drift: κάθε τοπικό μοντέλο παράγει gradient σε διαφορετική κατεύθυνση, με αποτέλεσμα το καθολικό μοντέλο να είναι ασταθές.

Κλείνοντας την εισαγωγή στην Ομοσπονδιακή Μάθηση, αξίζει να σημειωθεί μία ακόμη αρχιτεκτονική λεπτομέρεια: η διαφοροποίηση μεταξύ Cross-Device FL και Cross-Silo FL (Σχήμα 2.6) [14]. Μέχρι τώρα έγινε αναφορά στην εκπαίδευση ενός ξεχωριστού τοπικού μοντέλου στην συσκευή κάθε χρήστη/client (cross-device FL). Αυτό μπορεί να είναι εφικτό για εφαρμογές με μικρό συνολικό πλήθος χρηστών, ωστόσο σε μεγάλες εφαρμογές εισάγει μια αστάθεια. Αφενός είναι υπολογιστικά δυσκολότερος και σαφώς πιο αργός ο συντονισμός χιλιάδων ή εκατομμυρίων συσκευών, αφετέρου πολλές από αυτές τις συσκευές δεν διαθέτουν τις τεχνικές προδιαγραφές για την εκπαίδευση ενός μοντέλου Μηχανικής Μάθησης (RAM, επεξεργαστική ισχύ, σταθερή σύνδεση στο διαδίκτυο κτλ). Για τον λόγο αυτό, επιστρατεύεται συχνά η αρχιτεκτονική cross-silo FL, η οποία λειτουργεί ως ένας συμβιβασμός μεταξύ της πλήρως centralized και της πλήρως federated υλοποίησης. Σε αυτή τη δομή, τα δεδομένα ομαδοποιούνται τοπικά σε αξιόπιστους «υπερκόμβους» (supernodes) ή «σιλό» οργανισμών (π.χ. νοσοκομεία ή περιφερειακοί διακομιστές) και επεξεργάζονται μαζικά (ως batch). Έτσι, αντί να συμμετέχουν απευθείας εκατομμύρια ευαίσθητες συσκευές στην εκπαίδευση, ο κεντρικός διακομιστής συντονίζει την εκπαίδευση μερικών δεκάδων ή εκατοντάδων υπολογιστικά ισχυρών και σταθερών υπερκόμβων. Με αυτό τον

τρόπο διασφαλίζεται ταυτόχρονα η ιδιωτικότητα σε επίπεδο οργανισμού/τομέα και η σταθερότητα του συστήματος εκπαίδευσης.



Σχήμα 2.6: Cross-silo FL (αριστερά): ο server S συνδέεται με τους υπερκόμβους N , καθένας από τους οποίους εξυπηρετεί τους τελικούς χρήστες U . Cross-device FL (δεξιά): ο server S συνδέεται απευθείας με τους τελικούς χρήστες U .

2.3 Εισαγωγή στην Θεωρία Γράφων


Σε αυτή την Ενότητα θα παρουσιαστούν συνοπτικά τα βασικά στοιχεία των Γράφων, μιας μαθηματικής αναπαράστασης εξαιρετικά χρήσιμης για την επίλυση πολλών προβλημάτων, και βασικό συστατικό στην παρούσα εργασία.

Οι Γράφοι (Graphs) αποτελούν μια δομή δεδομένων που χρησιμοποιείται στα μαθηματικά και στην επιστήμη υπολογιστών για να αναπαραστήσει πολύπλοκες σχέσεις μεταξύ οντοτήτων. Συγκεκριμένα, τα βασικά στοιχεία ενός γράφου είναι οι κόμβοι (nodes/vertices), που αναπαριστούν τα σημεία/οντότητες, και οι ακμές (edges), που αναπαριστούν τις συνδέσεις μεταξύ των κόμβων. Ένας αυστηρός μαθηματικός ορισμός [20] είναι ο εξής:

Ένας απλός γράφος $G = (\mathcal{V}, \mathcal{E})$ αποτελείται από ένα μη κενό, πεπερασμένο σύνολο $\mathcal{V}$ στοιχείων που ονομάζονται κόμβοι, καθώς και από ένα πεπερασμένο σύνολο $\mathcal{E}$ που αποτελείται από διακριτά, μη διατεταγμένα ζεύγη $\{v_i, v_j\}$ στοιχείων του $\mathcal{V}$, τα οποία ονομάζονται ακμές.

Ένας γράφος μπορεί να ταξινομηθεί ως κατευθυνόμενος (directed), όταν οι ακμές μεταξύ των κόμβων του έχουν ορισμένο προσανατολισμό (από έναν κόμβο-πηγή σε έναν κόμβο-στόχο), ή μη κατευθυνόμενος (undirected) εάν οι συνδέσεις είναι συμμετρικές. Οι γράφοι μπορούν να ταξινομηθούν περαιτέρω βάσει της τοπολογίας τους


(π.χ. πλήρεις γράφοι, δένδρα, κυκλικοί γράφοι κ.ά.) [20], ωστόσο η παρούσα εργασία επικεντρώνεται στην ανάλυση απλών κατευθυνόμενων γράφων.



Σχήμα 2.7: Παραδείγματα γράφων: μη κατευθυνόμενος γράφος με 6 κόμβους και 7 ακμές (αριστερά) και κατευθυνόμενος γράφος με 5 κόμβους και 5 ακμές (δεξιά).

Η απλότητα αυτής της δομής παρέχει μια ευελιξία στην γκάμα των εφαρμογών που μπορεί να μοντελοποιήσει. Αυτό επιτυγχάνεται μέσω της αντιστοίχισης ενός διανύσματος χαρακτηριστικών (feature vector) στους κόμβους ή/και στις ακμές ενός γράφου, που περιγράφει εσωτερικές ιδιότητες, λειτουργίες, μοτίβα και κανόνες που επικρατούν μεταξύ τους. Για παράδειγμα, εάν αντιστοιχίσουμε τους κόμβους ενός γράφου σε ερευνητές και τις ακμές σε κοινές ακαδημαϊκές δημοσιεύσεις, προκύπτει ένας γράφος συνεργασιών που αναδεικνύει λανθάνοντα μοτίβα της ακαδημαϊκής κοινότητας.

Ο μηχανισμός αυτός αξιοποιείται στο πλαίσιο της παρούσας εργασίας για να περιγράψει τα συστήματα IoT. Εάν μοντελοποιήσουμε το σύνολο των IoT συσκευών ενός χρήστη ως έναν γράφο (Σχήμα 2.8), όπου κάθε κόμβος αποτελεί μία διακριτή συσκευή (π.χ. κάμερα ασφαλείας, έξυπνος λαμπτήρας) και κάθε ακμή έναν κανόνα αυτοματοποίησης μεταξύ τους (π.χ. αν εντοπιστεί κίνηση → ανάψε), τότε μπορούμε να περιγράψουμε με μεγάλη σαφήνεια τις σχέσεις αλληλεπίδρασης των συσκευών ενός χρήστη και να εξάγουμε αποτελέσματα για τον τρόπο λειτουργίας κάθε συσκευής, μελετώντας αποκλειστικά την μορφή του γράφου.




Σχήμα 2.8: Γράφος IoT συσκευών με τύπους ακμών και κόμβων: κάθε κόμβος περιέχει το μοτίβο της συσκευής και κάθε ακμή έναν κανόνα.

2.4 Graph Neural Networks (GNNs)

Τα κλασικά Νευρωνικά Δίκτυα που παρουσιάστηκαν στην [Ενότητα 2.1.2](#) έχουν την δυνατότητα να επεξεργάζονται δεδομένα σε μορφή διανυσμάτων, πινάκων, και, κατ' επέκταση εικόνων, ωστόσο δεν είναι εγγενώς συμβατά με την δομή των γράφων που περιγράφηκε παραπάνω, καθώς δεν μπορούν να αναπαραστήσουν την τοπολογική σύνδεση μεταξύ γειτονικών κόμβων. Για τον λόγο αυτό εισήχθη μία παραλλαγή των κλασικών Νευρωνικών Δικτύων, τα Graph Neural Networks (GNNs) [\[21\]](#). Τα GNNs εντάσσονται στον ευρύτερο ερευνητικό τομέα του graph representation learning, ο οποίος περιλαμβάνει αλγορίθμους αναπαράστασης της δομής των γράφων με μορφή διανυσμάτων, όπως ο node2vec [\[22\]](#) και ο DeepWalk [\[23\]](#). Σκοπός αυτών των τεχνικών είναι να κωδικοποιήσουν την πληροφορία των features των κόμβων, καθώς και την τοπολογία του γράφου, σε διανύσματα σταθερού μεγέθους, αντιληπτά από αλγορίθμους βαθιάς μάθησης. Αυτή η διαδικασία ονομάζεται graph embedding.

Η πρώτη αρχιτεκτονική GNNs εισήχθη το 2009 από τους Scarselli et al. [\[21\]](#) και η βασική αρχή της είναι ότι η κατάσταση κάθε κόμβου στο δίκτυο δεν καθορίζεται αυτόνομα, αλλά θα πρέπει να επηρεάζεται και από αυτή των γειτόνων του, καθώς είναι συνδεδεμένος με αυτούς τοπολογικά. Έτσι το δίκτυο «απορροφά» την τοπολογία του γράφου κατά την διαδικασία αλλαγής των βαρών του. Η τεχνική αυτή αναπτύχθηκε περαιτέρω, σχηματίζοντας τον μηχανισμό του Message Passing ([Σχήμα 2.10](#)) [\[25\]](#), δη-



Σχήμα 2.9: Ένα GNN layer: Τα χαρακτηριστικά του γράφου διέρχονται από ένα MLP (βλ. Εν. 2.1.2) και παράγουν έναν ανανεωμένο γράφο [24].


λαδή της «ανταλλαγής μηνυμάτων» μεταξύ των κόμβων του δικτύου μέσω των ακμών που τους συνδέουν. Σε αυτό το πλαίσιο, κάθε κόμβος-στόχος v ενημερώνει την κατάστασή του αντλώντας πληροφορία από τους συνδεδεμένους γείτονές του u . Ειδικότερα, για κάθε γείτονα παράγεται ένα «μήνυμα» μέσω μιας συνάρτησης $f_e(h_u, h_v, e_{uv})$, η οποία λαμβάνει υπόψη:

- την τρέχουσα κατάσταση του κόμβου-στόχου h_v ,
- την τρέχουσα κατάσταση του γειτονικού κόμβου h_u ,
- τα χαρακτηριστικά της μεταξύ τους ακμής e_{uv} .

Αυτά τα επιμέρους μηνύματα από όλους τους γείτονες συγκεντρώνονται μέσω μιας συνάρτησης συνάθροισης (aggregation function), όπως είναι η μέση τιμή (mean) ή το μέγιστο (max). Τέλος, η αθροιστική αυτή πληροφορία περνά από μια συνάρτηση ανανέωσης (update function, συνήθως ένα μη γραμμικό νευρωνικό επίπεδο) για να παραχθεί η νέα κατάσταση του κόμβου v . Η επιλογή των τριών αυτών συναρτήσεων εξαρτάται από την εκάστοτε υλοποίηση. Ενδεικτικές αρχιτεκτονικές αποτελούν τα Graph Convolutional Networks (GCNs) [26], τα Graph Attention Networks (GATs) [27] και το GraphSAGE [28].

Η διαδικασία αυτή εκτελείται ταυτόχρονα για όλους τους κόμβους του δικτύου. Με την ολοκλήρωση ενός επιπέδου του GNN, κάθε κόμβος έχει ενσωματώσει πληροφορία από τους άμεσους (1-hop) γείτονές του. Η προσθήκη πολλαπλών επιπέδων επιτρέπει στο δίκτυο να αντλήσει πληροφορία από έμμεσους γείτονες (τους γείτονες των γειτόνων κάθε κόμβου). Γενικεύοντας, ένα GNN k επιπέδων καθορίζει την επό-

μενη κατάσταση κάθε κόμβου από αυτή των k -hop γειτόνων του. Παρότι περισσότερα επίπεδα επιτρέπουν την κατανόηση βαθύτερων δομών, αυξάνουν δραματικά το υπολογιστικό κόστος και συχνά οδηγούν στο φαινόμενο του oversmoothing [29] των χαρακτηριστικών κάθε κόμβου, γι' αυτό και πρακτικά τα περισσότερα GNNs περιορίζονται σε 2 ή 3 επίπεδα.




Σχήμα 2.10: Η διαδικασία του message passing: ο κόμβος με γέμισμα (αριστερά) κάνει aggregate πληροφορία από τον εαυτό του και τους δύο γείτονές του και ανανεώνει την κατάστασή του (δεξιά) μέσω μιας update function. Η διαδικασία γίνεται σε κάθε κόμβο του γράφου [24].

Μία αρχιτεκτονική που αξίζει περαιτέρω ανάπτυξη, καθώς χρησιμοποιείται στην μεθοδολογία της παρούσας διπλωματικής, είναι αυτή του GraphSAGE (Sample and Aggregate) (Σχήμα 2.11) [28]. Ο αλγόριθμος σχεδιάστηκε για να παράγει embeddings επαγωγικά μέσα από την επαναληπτική διαδικασία τριών βημάτων που αναφέρθηκε παραπάνω: sampling, aggregation, update:

1. **Sampling:** Το δίκτυο δεν εξετάζει το σύνολο των κόμβων που συνδέονται με τον v , αλλά επιλέγει τυχαία ένα σταθερό πλήθος γειτόνων u .
2. **Aggregation:** Στη συνέχεια, τα χαρακτηριστικά αυτών των γειτόνων u συγκεντρώνονται σε ένα ενιαίο διάνυσμα μέσω μιας aggregation function, συνήθως της μέσης τιμής (mean aggregation).

3. **Update:** Αφού εξαχθεί η πληροφορία των γειτόνων, παράγεται η συνένωση (concatenation) του τρέχοντος διανύσματος του κόμβου v με το νέο, συναθροισμένο διάνυσμα των γειτόνων του και το αποτέλεσμα πολλαπλασιάζεται με τον πίνακα βαρών του συγκεκριμένου επιπέδου και διέρχεται από μία μη γραμμική συνάρτηση ενεργοποίησης (συνήθως ReLU), παράγοντας την τελική ανανεωμένη αναπαράσταση του κόμβου.

Επαναλαμβάνοντας αυτή τη διαδικασία για k επίπεδα (όπου συνήθως $k = 2$), ο τελικός κόμβος αποκτά ένα embedding που έχει ενσωματώσει επιτυχώς τόσο τα δικά του χαρακτηριστικά, όσο και την συντακτική και τοπολογική δομή της άμεσης και έμμεσης γειτονιάς του.




Σχήμα 2.11: Τα τρία βήματα του GraphSAGE: sampling γειτόνων, aggregation και update [28].

Ανεξαρτήτως της επιμέρους αρχιτεκτονικής, τα embeddings που παράγει ένα GNN αποτελούν τη βάση για το τελικό ζητούμενο, την πρόβλεψη: ένα τελικό επίπεδο (π.χ. ένα MLP) τα αξιοποιεί ώστε να παραγάγει προβλέψεις σε επίπεδο κόμβου, ακμής ή ολόκληρου του γράφου (Σχήμα 2.12). Στην παρούσα εργασία το ζητούμενο είναι η πρόβλεψη νέων ακμών, δηλαδή νέων κανόνων μεταξύ των συσκευών ενός χρήστη.


2.5 Συστήματα Σύστασης

Στις ακόλουθες παραγράφους επεξηγείται το πρόβλημα της παραγωγής προτάσεων και η δομή των Συστημάτων Σύστασης (Recommender Systems) [30], καθώς και η



Σχήμα 2.12: Αξιοποίηση ενός GNN για πρόβλεψη: τα embeddings που παράγονται από τα επίπεδα message passing τροφοδοτούν ένα τελικό επίπεδο πρόβλεψης [24].

άμεση εφαρμογή τους στα IoT οικοσυστήματα. Τα Συστήματα Σύστασης είναι ένα πεδίο της επιστήμης της Ανάλυσης Δεδομένων το οποίο ασχολείται με τον εντοπισμό λανθανόντων μοτίβων από μεγάλα σύνολα δεδομένων χρηστών, με σκοπό το προσωποποιημένο φιλτράρισμα πληροφορίας. Η κεντρική ιδέα είναι η μελέτη και αξιολόγηση των επιλογών κάθε χρήστη με βάση το δικό του ιστορικό και τα γενικευμένα μοτίβα του συνόλου. Για παράδειγμα, μία μηχανή αναζήτησης ταινιών εξετάζει το ιστορικό και τις βαθμολογίες που έχει δώσει ήδη ο εκάστοτε χρήστης (content-based filtering), υπολογίζει τον βαθμό ομοιότητάς του με άλλους χρήστες (collaborative filtering), και του προτείνει μια νέα ταινία με στατιστικά πολύ μεγαλύτερη πιθανότητα να τον ικανοποιήσει απ' ό,τι μια τυχαία επιλογή.



Σχήμα 2.13: Επισκόπηση ενός συστήματος σύστασης: Αρχικά, οι χρήστες δηλώνουν τις προτιμήσεις τους (αριστερά). Στην συνέχεια το σύστημα προβλέπει τις προτιμήσεις κάθε χρήστη για τα αντικείμενα που δεν έχει βαθμολογήσει ακόμη (ερωτηματικά στον πίνακα δεξιά).

Στα IoT οικοσυστήματα, που αποτελούν και το αντικείμενο της παρούσας εργασίας, τα συστήματα σύστασης έρχονται να επιλύσουν το πρόβλημα της αδράνειας χρη-

στών. Αυτό που κάνει τις IoT συσκευές «έξυπνες» είναι η δυνατότητά τους να αυτοματοποιούνται. Για παράδειγμα, ένας έξυπνος θερμοστάτης διαφοροποιείται από έναν συμβατικό διότι μπορεί να ενεργοποιείται ασύρματα βάσει γεωγραφικής θέσης ή συγκεκριμένου χρονοδιαγράμματος και να λειτουργεί συνεργατικά με άλλες έξυπνες συσκευές όπως λαμπτήρες ή αισθητήρες κίνησης, με βάση ορισμένους κανόνες. Η διαχείριση τέτοιων κανόνων ωστόσο εναπόκειται συνήθως στους ίδιους τους χρήστες, οι περισσότεροι εκ των οποίων καταλήγουν να ορίζουν ελάχιστους ή και κανέναν, με αποτέλεσμα οι συσκευές να υπολειτουργούν ως απλά, τηλεχειριζόμενα εργαλεία. Εδώ ακριβώς έγκειται η αξία της έξυπνης σύστασης κανόνων (rule recommendation): η αυτοματοποίηση του ίδιου του συστήματος αυτοματοποίησης.

Οι αρχιτεκτονικές που χρησιμοποιούνται για την παραγωγή προτάσεων ποικίλουν δραστικά [31], από αμιγώς στατιστικές μεθόδους παραγοντοποίησης πινάκων (matrix factorization) (περαιτέρω ανάλυση στην [Ενότητα 3.2](#)) έως βαθιά Νευρωνικά Δίκτυα. Ο στόχος τους όμως είναι πάντοτε ο ίδιος: δεδομένης της υπάρχουσας τοπικής πληροφορίας (ποιες συσκευές και ποιους κανόνες κατέχει ήδη ο χρήστης), και λαμβάνοντας υπόψη την πληροφορία όλων των χρηστών (ποιοι κανόνες εμφανίζονται συχνότερα στο σύνολο του δικτύου), το σύστημα προβλέπει και προτείνει στον χρήστη τον νέο κανόνα που έχει την μεγαλύτερη πιθανότητα να είναι του χρήσιμος.

Ολοκληρώνοντας το παρόν Κεφάλαιο, έχουν τεθεί πλέον όλα τα θεωρητικά θεμέλια για τη μοντελοποίηση του προβλήματος που καλείται να επιλύσει η παρούσα εργασία: η ανάπτυξη ενός συστήματος σύστασης για IoT οικοσυστήματα, το οποίο μοντελοποιεί ένα δοθέν σύνολο δεδομένων ως γράφους και εκπαιδεύει ένα μοντέλο GNN μέσα σε ένα ομοσπονδιακό περιβάλλον, με στόχο την διασφάλιση όχι μόνο της υψηλής υπολογιστικής αποδοτικότητας αλλά και της προστασίας της ιδιωτικότητας των χρηστών.

Κεφάλαιο 3

Περιγραφή του προβλήματος

3.1 Ο διαγωνισμός της Wyze: κίνητρα και δεδομένα

Στο πλαίσιο της ανάπτυξης καινοτόμων τεχνολογιών στον χώρο του Διαδικτύου των Πραγμάτων, η τεχνολογική εταιρεία Wyze διεξήγαγε έναν διαγωνισμό με σκοπό τη δημιουργία αλγορίθμων έξυπνης σύστασης κανόνων για IoT συσκευές. Στόχος αυτών των αλγορίθμων είναι να προτείνουν στους χρήστες που κατέχουν τέτοιες συσκευές (π.χ. κάμερες, έξυπνες λάμπες, αισθητήρες κίνησης κ.ά.) νέους, προσωποποιημένους τρόπους να αυτοματοποιήσουν τη λειτουργία τους, βασιζόμενοι στα μοτίβα και το ιστορικό χρήσης τους. Έχοντας πολυετή παρουσία στον χώρο του IoT, η Wyze διαμόρφωσε ένα σύνολο δεδομένων που προέρχεται από περισσότερους από 300.000 πραγματικούς χρήστες και περιλαμβάνει πάνω από 1.000.000 κανόνες [2]. Ωστόσο ένας αλγόριθμος που επεξεργάζεται αυτά τα δεδομένα και εξαγεί μοτίβα χρήσης προκαλεί έντονη ανησυχία για την ιδιωτικότητα και την προστασία των προσωπικών δεδομένων των χρηστών. Για τον λόγο αυτό, προτάθηκε μία εναλλακτική προσέγγιση στο πρόβλημα μέσω της Ομοσπονδιακής Μάθησης [4]. Η μέθοδος αυτή εξασφαλίζει ότι το τοπικό μοντέλο εκπαιδεύεται αποκλειστικά στη συσκευή του εκάστοτε χρήστη, ανταλλάσσοντας με τον κεντρικό server μόνο τις αναβαθμισμένες παραμέτρους και ποτέ τα ίδια τα ευαίσθητα δεδομένα.

Η Wyze μοντελοποίησε τους κανόνες του κάθε χρήστη μέσω μιας τριπλέτας της μορφής «συσκευή – κανόνας – συσκευή». Σύμφωνα με αυτή τη δομή, όταν η πρώτη συσκευή βρεθεί σε μία συγκεκριμένη κατάσταση (π.χ. ένας αισθητήρας εντοπίζει κίνηση), τότε πυροδοτείται η δράση της δεύτερης συσκευής (π.χ. ένας λαμπτήρας ανάβει). Το παραπάνω παράδειγμα, δηλαδή, εκφράζεται ως η τριπλέτα «αισθητήρας κίνησης – εντοπισμός κίνησης → ενεργοποίηση – λαμπτήρας».

Επειδή το σύνολο δεδομένων της Wyze προέρχεται από πραγματικούς χρήστες, αντικατοπτρίζει αναπόφευκτα την τεράστια ποικιλομορφία στον τρόπο με τον οποίο διαφορετικοί άνθρωποι χρησιμοποιούν το IoT οικοσύστημά τους. Αυτό έχει ως αποτέλεσμα τα δεδομένα να μην ακολουθούν Ανεξάρτητες και Ταυτόσημα Κατανομημένες



Σχήμα 3.1: Η τριπλέτα «συσκευή – κανόνας – συσκευή»: μια συσκευή-πηγή (κάμερα A) σε συγκεκριμένη κατάσταση (ανίχνευση κίνησης) πυροδοτεί μια δράση (άναψε) σε μια συσκευή-στόχο (λαμπτήρας B).

(IID) κατανομές, να είναι δηλαδή ετερογενή, όπως αναλύθηκε στην [Ενότητα 2.2.2](#). Συγκεκριμένα, παρατηρήθηκε ότι το μεγαλύτερο μέρος των χρηστών κατέχει πολύ λίγες συσκευές και έχει δημιουργήσει ελάχιστους κανόνες μεταξύ τους, δημιουργώντας μία κατανομή μακράς ουράς (long-tailed distribution), όπως καταδεικνύεται στο [Σχήμα 5.2](#). Η κατάσταση αυτή εισάγει έντονη αραιότητα στα δεδομένα. Η εξαγωγή χρήσιμων μοτίβων από ένα τόσο αραιό και ετερογενές σύνολο καθιστά την εκπαίδευση ενός μοντέλου μηχανικής μάθησης σαφώς δυσκολότερη απ' ό,τι σε πυκνά σύνολα δεδομένων, πόσο μάλλον όταν αυτή η εκπαίδευση πρέπει να πραγματοποιηθεί ομοσπονδιακά.

3.2 Μοντελοποίηση του προβλήματος


Όπως εξετάστηκε και στην [Ενότητα 2.5](#), το πρόβλημα της Wyze εντάσσεται στην ευρύτερη κατηγορία των συστημάτων σύστασης. Σκοπός των συστημάτων αυτών είναι η πρόβλεψη μιας νέας πληροφορίας (π.χ. η επόμενη ταινία που θα ενδιέφερε έναν χρήστη), βασιζόμενη τόσο στα υπάρχοντα δεδομένα του ίδιου του χρήστη (ιστορικό θεάσεων), όσο και σε δεδομένα χρηστών με παρόμοια συμπεριφορά.

Η κυρίαρχη μέθοδος μοντελοποίησης τέτοιων προβλημάτων, η οποία διαδόθηκε ευρέως μέσω του διαγωνισμού της εταιρείας Netflix το 2009, βασίζεται στην παραγοντοποίηση πινάκων (matrix factorization) [32]. Σε αυτή την προσέγγιση, οι χρήστες και τα αντικείμενα (π.χ. ταινίες) αναπαριστώνται μέσω ενός πίνακα, όπου κάθε γραμμή αντιστοιχεί σε έναν χρήστη και κάθε στήλη σε ένα αντικείμενο. Ο πίνακας αυτός είναι μερικώς συμπληρωμένος (π.χ. στον χρήστη 3 άρεσαν οι ταινίες 2, 5 και 7, δεν άρεσε η ταινία 1 και δεν έχει αξιολογήσει τις υπόλοιπες). Στόχος είναι η πρόβλεψη των κενών τιμών του πίνακα, αξιοποιώντας τα λανθάνοντα μοτίβα που εμφανίζονται στο σύνολό του. Οι τεχνικές που χρησιμοποιούνται για αυτή τη συμπλήρωση ποικίλλουν, ωστόσο η ανάλυσή τους εκφεύγει του σκοπού της παρούσας εργασίας.

Υπάρχουν μερικές σημαντικές λεπτομέρειες του μοντέλου αυτού οι οποίες το καθιστούν μη λειτουργικό για το περιβάλλον των IoT συσκευών της Wyze [4]. Αρχικά, οι σχέσεις μεταξύ των έξυπνων συσκευών είναι υπερβολικά περίπλοκες για να αποτυπωθούν αποτελεσματικά σε έναν απλό πίνακα (user-item matrix). Για παράδειγμα, ενώ ένα σύστημα πρόβλεψης αγορών μοντελοποιεί κυρίως απλές δυαδικές σχέσεις (π.χ. αγορά/μη αγορά), μία IoT αλληλεπίδραση ενέχει προϋποθέσεις και λογική (π.χ. «αν η κάμερα εντοπίσει κίνηση, τότε ο λαμπτήρας ανάβει» ή «αν η ώρα είναι 17:00, τότε το ρολό σκίασης κατεβαίνει»). Επιπλέον, ένας χρήστης συχνά κατέχει πολλές συσκευές του ίδιου ακριβώς τύπου (π.χ. τρεις έξυπνους λαμπτήρες σε διαφορετικά δωμάτια). Για να διαχωριστούν αυτές σε έναν πίνακα, θα απαιτούνταν ξεχωριστές στήλες για την καθεμία, γεγονός που θα καθιστούσε τον συνολικό πίνακα για εκατοντάδες χιλιάδες χρήστες όχι μόνο υπολογιστικά τεράστιο, αλλά και εξαιρετικά αραιό. Τέλος, η διατήρηση ενός κεντρικού πίνακα που συγκεντρώνει όλη την πληροφορία για τις συσκευές όλων των χρηστών εγείρει σοβαρούς κινδύνους ιδιωτικότητας, καθώς μία ενδεχόμενη παραβίαση αρκεί για να εκθέσει ευαίσθητα προσωπικά δεδομένα, όπως συνέβη στο παρελθόν σε αντίστοιχες πλατφόρμες, συμπεριλαμβανομένης της Wyze [33].

Για τον λόγο αυτό προτάθηκε η εναλλακτική αναπαράσταση των χρηστών και των συσκευών τους μέσω γράφων. Όπως παρουσιάστηκε συνοπτικά στην [Ενότητα 2.3](#), κάθε χρήστης $u_k \in \mathcal{U}$ εκφράζεται από έναν γράφο $\mathcal{G}_k = \{\mathcal{V}_k, \mathcal{X}_k, \mathcal{E}_k\}$. Σε αυτόν, οι κόμβοι $\mathcal{V}_k$ αναπαριστούν τις διαφορετικές συσκευές του χρήστη, οι ακμές $\mathcal{E}_k$ αναπαριστούν τους ενεργούς κανόνες μεταξύ τους (τη δομή «συσκευή – κανόνας – συσκευή»), και τα χαρακτηριστικά $\mathcal{X}_k$ περιγράφουν τις ιδιότητες κάθε κόμβου (λειτουργίες, δυνατές συνδέσεις, πιθανές καταστάσεις). Η προσέγγιση αυτή επιλύει εγγενώς τις αδυναμίες του πίνακα: η πολυπλοκότητα των κανόνων μεταξύ συσκευών εκφράζεται ελεύθερα μέσω των ακμών που τις συνδέουν, κάθε χρήστης μπορεί να έχει όσες συσκευές του ίδιου τύπου θέλει χωρίς να επηρεάζει τους άλλους χρήστες, και κυρίως, ο κάθε χρήστης διατηρεί τον δικό του απομονωμένο γράφο, προστατεύοντας έτσι την τοπολογία του έξυπνου σπιτιού του.

Βάσει αυτού του ανανεωμένου μοντέλου, ο στόχος ορίζεται με σαφήνεια: η πρόταση νέων κανόνων (ακμών) μεταξύ των υπάρχουσών συσκευών (κόμβων) του κάθε χρήστη, αξιοποιώντας την αφηρημένη γνώση που εξάγεται τόσο από τον δικό του γράφο όσο και από το δίκτυο των υπολοίπων. Αυτό υλοποιείται μαθηματικά μέσω μιας διπλής διαδικασίας: πρώτον, του node embedding (βλ. [Ενότητα 2.4](#)), δηλαδή της κωδικοποίησης των χαρακτηριστικών $\mathcal{X}_k$ και της τοπολογίας σε διανυσματικές αναπαραστάσεις που περιγράφουν τις ιδιότητες κάθε συσκευής, και δεύτερον, της πρόβλε-



Σχήμα 3.2: Οι δύο αναπαραστάσεις του προβλήματος: ο user-item πίνακας του matrix factorization (αριστερά) έναντι της αναπαράστασης ανά χρήστη με γράφο (δεξιά).

ψης συνδέσεων (link prediction), η οποία αξιολογεί τα παραγόμενα διανύσματα για να προτείνει τις νέες ακμές με τη μεγαλύτερη πιθανότητα να φανούν χρήσιμες στον τελικό χρήστη.

3.3 Διαχείριση δεδομένων

Το μοντέλο της Wyze παρουσιάζει δύο θεμελιώδεις προκλήσεις, εγγενείς στην φύση των πραγματικών IoT δεδομένων των χρηστών. Η πρώτη αφορά την ακραία αραιότητα των δεδομένων. Ένας μέσος χρήστης κατέχει έναν αριθμό συσκευών (π.χ. 8 έξυπνους λαμπτήρες και μία κάμερα), αλλά έχει διαμορφώσει ελάχιστους ενεργούς κανόνες (ακμές) μεταξύ τους (π.χ. 2 κανόνες για τον χειρισμό του φωτισμού και άλλον έναν για την παρακολούθηση της κάμερας). Συγκριτικά, σε έναν πλήρως συνδεδεμένο, κατευθυνόμενο γράφο $n = 8$ κόμβων, οι πιθανές ακμές είναι $n(n - 1) = 56$. Σε ένα σύστημα πρόβλεψης συνδέσεων, το μοντέλο καλείται να ταξινομήσει κάθε πιθανή ακμή, με την πλειονότητα του γράφου να ανήκει στην κλάση «μη σύνδεση» (στο παράδειγμά μας 53 από τις 56 δυνατές ακμές δεν έχουν κάποιον κανόνα). Εάν από τις 56 πιθανές ακμές μόνο οι 3 είναι υπαρκτές, προκύπτει εντονότατη ανισορροπία κλάσεων (class imbalance) [34]. Συνέπεια αυτού είναι το «παράδοξο της ακρίβειας» (accuracy paradox): το μοντέλο τείνει να προβλέπει σταθερά την κλάση της «μη σύνδεσης», επιτυγχάνοντας φαινομενικά εξαιρετική ακρίβεια $53/56 \approx 94.6\%$, χωρίς όμως να εξάγει καμία ουσιαστική γνώση για το σύστημα σύστασης.

Για την αντιμετώπιση αυτής της πρόκλησης, το σύστημα FedRule της Wyze εισάγει τη μέθοδο της δειγματοληψίας αρνητικών ακμών (negative sampling) [34]. Κατά την

τοπική εκπαίδευση, το μοντέλο δεν εξετάζει το σύνολο των συνδέσεων του γράφου, αλλά ένα τεχνητά περιορισμένο υποσύνολό τους, το οποίο περιλαμβάνει όλες τις θετικές ακμές (τους πραγματικούς κανόνες, στο παράδειγμά μας, τρεις) μαζί με ένα τυχαίο υποσύνολο αρνητικών ακμών, σε κάποια θεμιτή αναλογία (π.χ. 1:1, έστω στο παράδειγμά μας, τέσσερις ακμές). Μέσω αυτής της τεχνητής εξισορρόπησης του δείγματος, η κλάση της «μη σύνδεσης» παύει να είναι συντριπτικά κυρίαρχη. Το μοντέλο δεν μπορεί πλέον να προτείνει αφελώς τον κανόνα «μη σύνδεση», διότι η ακρίβεια αυτής της πρόβλεψης είναι πολύ κακή (εδώ $4/7 \approx 57.1\%$), και έτσι αναγκάζεται να εντοπίσει πραγματικά λανθάνοντα μοτίβα για να διαχωρίσει τις έγκυρες από τις άκυρες συνδέσεις, οδηγώντας σε χρήσιμες και ακριβείς συστάσεις.

Το δεύτερο πρόβλημα αφορά τη φύση των ετερογενών δεδομένων. Όπως αναφέρθηκε στην [Ενότητα 3.1](#), οι κατανομές δεδομένων μεταξύ των χρηστών δεν είναι ανεξάρτητες και ταυτόσημα κατανομημένες (non-IID). Για παράδειγμα, ένας χρήστης μπορεί να διαθέτει αποκλειστικά έξυπνους λαμπτήρες, ενώ ένας άλλος κυρίως κάμερες ασφαλείας. Σε ένα καθεστώς ομοσπονδιακής μάθησης, όπου κάθε χρήστης εκπαιδεύει το δικό του τοπικό μοντέλο και πραγματοποιεί gradient descent με βάση τα δεδομένα που έχει στην διάθεσή του (βλ. [Ενότητα 2.2](#)), αυτές οι αποκλίσεις στον όγκο και το είδος των δεδομένων αυξάνουν τη διακύμανση των κλίσεων των χρηστών, οδηγώντας το σύστημα σε client drift [19] (βλ. [Ενότητα 2.2.2](#)).

Για να αντισταθμίσει την πρόκληση αυτή, η Wyze ενσωμάτωσε στον αλγόριθμό της μια τεχνική μείωσης της διακύμανσης (variance reduction), βασισμένη στην χρήση διορθωτικών παραμέτρων ελέγχου (control parameters) κατ' αντιστοιχία με τον αλγόριθμο FedGATE [35], στο πνεύμα και άλλων μεθόδων μείωσης διακύμανσης με παραμέτρους ελέγχου όπως το SCAFFOLD [19]. Συγκεκριμένα, κάθε client k διατηρεί τοπικά δύο παραμέτρους ελέγχου: την δ_{θ_k} για το μοντέλο του GNN και την δ_{ϕ_k} για το μοντέλο πρόβλεψης του κανόνα. Ανατρέχοντας πίσω στην ροή εκπαίδευσης της [Ενότητας 2.2](#), παρατηρούμε την εξής αλλαγή: Κατά τον υπολογισμό των κλίσεων g_{θ_k} και g_{ϕ_k} , το τοπικό μοντέλο δεν προχωρά σε άμεση ενημέρωση των βαρών του. Αντιθέτως, αφαιρεί από τις κλίσεις τις παραμέτρους δ_{θ_k} , δ_{ϕ_k} , παράγοντας έτσι διορθωμένες κλίσεις που αποτρέπουν την υπερβολική απόκλιση από το κεντρικό μοντέλο. Μετά το πέρας της τοπικής εκπαίδευσης, οι clients αποστέλλουν στον κεντρικό server μόνο τις συνολικές διαφορές των βαρών τους Δ_{θ} , Δ_{ϕ} . Ο server υπολογίζει τον μέσο όρο αυτών των διαφορών και τον μεταδίδει πίσω στους clients. Χρησιμοποιώντας αυτόν τον παγκόσμιο μέσο όρο, κάθε client αναπροσαρμόζει τις δικές του τοπικές παραμέτρους ελέγχου δ_{θ_k} και δ_{ϕ_k} . Αυτή η διαδικασία συνεχούς διόρθωσης εξασφαλίζει ότι τα ετερογενή τοπικά μοντέλα διατηρούν κοινό προσανατολισμό, επιτρέποντας στο global μο-

ντέλο να συγκλίνει γρήγορα και με σταθερότητα σε μία λύση αρκετά ικανοποιητική για όλους τους χρήστες.

3.4 Το αρχικό μοντέλο της Wyze

Μαζί με την δημοσίευση του paper της [4], η Wyze διέθεσε ανοιχτά μία αρχική υλοποίηση [5] για να χρησιμοποιηθεί ως βάση στον διαγωνισμό. Στόχος δεν ήταν η αυτούσια πειραματική απόδειξη των αποτελεσμάτων του paper, αλλά η παροχή ενός καθοδηγητικού πλαισίου προς τους διαγωνιζόμενους. Για αυτό τον λόγο παρατηρείται μία πολύ απλοποιημένη αρχιτεκτονική σε σχέση με αυτή που προτάθηκε στο paper.


3.4.1 Το pipeline του μοντέλου

Προετοιμασία δεδομένων

Τα σύνολα δεδομένων που δόθηκαν στους διαγωνιζόμενους απαρτίζονται από 16 διαφορετικές κατηγορίες συσκευών. Η υλοποίηση της Wyze αντιστοιχίζει ένα ID σε καθεμία από αυτές τις κατηγορίες, αγνοώντας την κατηγορία “Cloud”, η οποία υπάρχει μόνο στο dataset των κανόνων και όχι σε αυτό των συσκευών. Στην συνέχεια, φιλτράρει όλες τις τριπλέτες «συσκευή – κανόνας – συσκευή» που εμφανίζονται λιγότερο από 10 φορές συνολικά, για να εκπαιδεύσει το μοντέλο σε δεδομένα που εμφανίζονται συχνά και όχι σε εξαιρέσεις, και δομεί το λεξιλόγιο των συσκευών και κανόνων για όλους τους χρήστες. Για την δημιουργία των γράφων κάθε χρήστη χρησιμοποιείται η βιβλιοθήκη Deep Graph Library (DGL) [36, 37]. Κάθε συσκευή αναπαρίσταται από έναν κόμβο, με τον τύπο της (π.χ. κάμερα, πρίζα) να κωδικοποιείται ως ένα one-hot διάνυσμα features. Οι κανόνες αναπαρίστανται ως ακμές, με τους τύπους τους (etypes) να αντιστοιχούν στην εκάστοτε τριπλέτα «συσκευή – κανόνας – συσκευή». Αν ο γράφος κάποιου χρήστη καταλήξει με 2 ή λιγότερους κόμβους, τότε απορρίπτεται. Στην συνέχεια, οι κόμβοι κάθε χρήστη χωρίζονται σε ποσοστό 80% για εκπαίδευση (training) και 20% για αξιολόγηση (testing). Τέλος, πριν την διαδικασία του training, εφαρμόζεται negative sampling στους γράφους: ο αλγόριθμος αναλύει τον πίνακα γειτνίασης (adjacency matrix) κάθε γράφου, εντοπίζει ζεύγη κόμβων που δεν συνδέονται και επιλέγει τυχαία ένα υποσύνολο αυτών, ώστε να χρησιμεύσουν ως αρνητικά παραδείγματα (λανθασμένες συνδέσεις) κατά την εκμάθηση.

Μοντέλα μηχανικής μάθησης

Όπως περιγράφεται και στο paper, η αρχιτεκτονική αποτελείται από δύο διακριτά μέρη: ένα Graph Neural Network (GNN) για την κωδικοποίηση της πληροφορίας των γράφων μέσω embeddings, και ένα μοντέλο link prediction για την πρόταση νέων ακμών. Για το πρώτο μέρος, η υλοποίηση πειραματίζεται με τα μοντέλα GCN [26], GAT [27] και GraphSAGE [28]. Όπως καταδεικνύεται στο ablation study (Ενότητα 4.5 του paper) [4], το GraphSAGE υπερσχύει, κυρίως λόγω της στιβαρής διαχείρισης κόμβων με μηδενικό βαθμό εισόδου (0-in-degree nodes). Έτσι χρησιμοποιείται η δομή του GraphSAGE που αναφέρεται στο paper: 2 επίπεδα SAGEConv με mean aggregation και ReLU ενεργοποίηση μετά το πρώτο επίπεδο. Το δεύτερο στάδιο της υλοποίησης αξιοποιεί ένα κλασικό πλήρως συνδεδεμένο Νευρωνικό Δίκτυο MLP 2 επιπέδων, το οποίο πραγματοποιεί concatenation των embeddings ενός source κόμβου και ενός destination κόμβου, τα περνάει από ένα κρυφό επίπεδο με ενεργοποίηση ReLU και υπολογίζει τις πιθανότητες εμφάνισης κάθε πιθανού κανόνα μέσω μιας σιγμοειδούς συνάρτησης.



Σχήμα 3.3: Η γενική αρχιτεκτονική του FedRule: κάθε χρήστης έχει το δικό του τοπικό μοντέλο GNN και prediction, τα βάρη των οποίων στέλνονται στον server για aggregation και update, ενώ τα τοπικά τους gradients διορθώνονται από τις παραμέτρους διόρθωσης [4].

Η διαδικασία του training

Εδώ εντοπίζεται η μεγαλύτερη διαφοροποίηση μεταξύ του paper της Wyze και της υλοποίησής της. Ενώ το paper αναπτύσσει έναν αλγόριθμο Federated Learning, τον FedRule, ως απάντηση στα ζητήματα ιδιωτικότητας και ετερογένειας των δεδομένων, η υλοποίηση που παρείχε στον διαγωνισμό εφαρμόζει τον αλγόριθμο GraphRule, μία αμιγώς centralized μέθοδο εκμάθησης. Δεν υπάρχει κάποια ουσιαστική διαφορά στα μοντέλα μηχανικής μάθησης ή τα datasets, παρά μόνο στην ενορχήστρωση της εκπαίδευσης. Εδώ, ο κεντρικός server έχει πλήρη πρόσβαση σε όλα τα δεδομένα όλων των χρηστών και εκπαιδεύει τα μοντέλα σε κεντρικό επίπεδο. Η στρατηγική aggregation FedRule περιγράφεται στο paper [4] αλλά δεν εμφανίζεται στον κώδικα.

Μετρικές

Η υλοποίηση της Wyze στηρίζει την αξιολόγησή της σε τρεις μετρικές: το Σφάλμα (Loss), το Area Under the Curve (AUC) και το Mean Rank (MR), ενώ το paper κάνει χρήση και της μετρικής HitRate@N.

Ως συνάρτηση σφάλματος χρησιμοποιείται η Binary Cross Entropy (BCE) Loss [12], η πιο συνήθης μετρική σφάλματος για προβλήματα ταξινόμησης με έξοδο κατανομή πιθανοτήτων στο διάστημα $[0, 1]$ (όπως στο δικό μας πρόβλημα, στο οποίο το μοντέλο εξάγει τις πιθανότητες μία ορισμένη ακμή να έχει χρησιμότητα για τον χρήστη). Όσο μικρότερη η BCE, τόσο πιο ακριβές το μοντέλο. Ο μαθηματικός της τύπος ορίζεται ως:

$$L_{BCE} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

όπου N το πλήθος των δειγμάτων, y_i η πραγματική ετικέτα (1 για υπαρκτό κανόνα, 0 για μη υπαρκτό) και p_i η προβλεπόμενη πιθανότητα από το μοντέλο.

Η μετρική AUC ποσοτικοποιεί την ικανότητα του μοντέλου να διακρίνει τα πραγματικά θετικά δείγματα (True Positives, TP) από τα ψευδώς θετικά (False Positives, FP, δηλαδή τις τεχνητά παραγόμενες αρνητικές ακμές κατά την διαδικασία του negative sampling). Υπολογίζεται ως το εμβαδόν κάτω από την καμπύλη ROC (Receiver Operating Characteristic) [38], η οποία σχεδιάζεται τοποθετώντας στον άξονα Y το ποσοστό των True Positives (TPR ή Sensitivity) και στον άξονα X το ποσοστό των False Positives (FPR, που ισούται με $1 - \text{Specificity}$). Μια τυχαία ταξινόμηση χαράσσει την ευθεία $y = x$ (AUC = 0.5), ενώ ένα τέλειο μοντέλο αγγίζει εμβαδόν 1.

Το Mean Rank (MR) [39] εκφράζει τη μέση θέση στην οποία κατατάσσεται ο πραγματι-

κός/επιθυμητός κανόνας μέσα στη φθίνουσα λίστα των πιθανοτήτων που παρήγαγε το δίκτυο. Μικρότερες τιμές υποδηλώνουν καλύτερη απόδοση. Αξίζει να σημειωθεί πως στην υλοποίηση της Wyze η αρίθμηση ξεκινά από το 0 (τέλεια πρόβλεψη: $MR=0$), σε αντίθεση με την καθιερωμένη ακαδημαϊκή πρακτική όπου η κορυφαία θέση ορίζεται ως 1η ($MR=1$).

Τέλος, το $\text{HitRate}@N$ [39] μετρά το ποσοστό των περιπτώσεων όπου ο σωστός κανόνας εμφανίζεται μέσα στις κορυφαίες N προτάσεις του συστήματος. Παρότι η αρχική υλοποίηση κώδικα δεν το υπολογίζει αυτόματα, η μετρική αυτή είναι θεμελιώδης τόσο στην ευρύτερη βιβλιογραφία όσο και στην παρούσα εργασία, καθώς αντικατοπτρίζει άμεσα την πρακτική χρησιμότητα του συστήματος για τον τελικό χρήστη.

3.4.2 Οι αδυναμίες του μοντέλου

Η υλοποίηση της Wyze θέτει μία ακέραια βάση για πειραματισμό, ωστόσο καθαυτή παρουσιάζει μία κρίσιμη αδυναμία: την μη ενσωμάτωση των τύπων των προϋπαρχόντων κανόνων κατά την εκπαίδευση του GNN. Παρότι το embedding των γράφων αφομοιώνει επιτυχώς τα χαρακτηριστικά των κόμβων (αναγνωρίζοντας, για παράδειγμα, ότι μια κάμερα σχετίζεται συχνά με αισθητήρες), το μοντέλο αντιμετωπίζει τις ακμές του γράφου ως απλές δυαδικές συνδέσεις, δεν κωδικοποιεί δηλαδή τον τύπο της προϋπάρχουσας αλληλεπίδρασης. Σε ένα σύνολο πραγματικών δεδομένων που αγγίζει το 1.000.000 κανόνων, η αδυναμία αξιοποίησης αυτής της πλούσιας συντακτικής πληροφορίας στερεί από το δίκτυο σημαντικό context, αναγκάζοντάς το να εξάγει συμπεράσματα αποκλειστικά από την τοπολογία, γεγονός που περιορίζει δραστικά τη μέγιστη δυνατή επίδοσή του.

3.5 Η δεύτερη θέση του διαγωνισμού

Σε αυτή την Ενότητα αναλύεται η προσέγγιση του διαγωνιζόμενου που κατέκτησε τη δεύτερη θέση στον διαγωνισμό [3]. Πρόκειται για μία centralized υλοποίηση που εφαρμόζει σημαντικές αρχιτεκτονικές βελτιώσεις σε όλο το pipeline της εκπαίδευσης. Καθώς πρόκειται για διαγωνισμό επιδόσεων, ο διαγωνιζόμενος έστρεψε την προσοχή του στην βελτιστοποίηση του σκορ του και όχι στα ζητήματα ιδιωτικότητας των χρηστών, ωστόσο η υλοποίησή του εξακολουθεί να παρουσιάζει έντονο ακαδημαϊκό ενδιαφέρον.

Η υλοποίηση αξιοποιεί την βιβλιοθήκη PyTorch Geometric (PyG) [40, 41] για την δια-

χείριση των γράφων και ακολουθεί επί το πλείστον τα ίδια βήματα με την baseline υλοποίηση της Wyze, με μερικές διαφοροποιήσεις που θα παρουσιαστούν παρακάτω.

Η ειδοποιός διαφορά που οδήγησε την υλοποίηση αυτή στην δεύτερη θέση είναι η αφομοίωση των τύπων των ακμών κάθε γράφου, που ήταν η μεγαλύτερη παράλειψη του μοντέλου της Wyze, όπως αναλύθηκε στην [Ενότητα 3.4.2](#). Συγκεκριμένα, το δίκτυο αυτό δεν χρησιμοποιεί embeddings μόνο για τους κόμβους, αλλά ενσωματώνει πληροφορία και στις ακμές (edge embeddings) [42], καθοδηγώντας το μοντέλο να αξιοποιήσει τα λανθάνοντα μοτίβα στους προϋπάρχοντες κανόνες μεταξύ των συσκευών των χρηστών. Αυτή η πυκνή πληροφορία στην συνέχεια αθροίζεται μέσω μιας custom aggregation συνάρτησης σε κάθε κόμβο. Ως αποτέλεσμα, το μοντέλο μαθαίνει το πλήρες πλαίσιο αλληλεπίδρασης κάθε συσκευής. Για παράδειγμα, δεν μαθαίνει απλώς ότι μία κάμερα συνδέεται με ένα σύστημα συναγερμού, αλλά κατανοεί ειδικά ότι η «αναγνώριση κίνησης» είναι αυτή που πυροδοτεί την ενεργοποίησή του.

Παράλληλα, στοχευμένες τροποποιήσεις στο υπόλοιπο pipeline οδηγούν σε περαιτέρω βελτιστοποιήσεις. Η υλοποίηση αξιοποιεί την βιβλιοθήκη Pandas [43, 44] για την ταχύτερη φόρτωση και ομαδοποίηση των συσκευών και κανόνων ανά χρήστη. Αφού οι γράφοι έχουν δημιουργηθεί, ο αλγόριθμος επιλέγει τυχαία και αποκρύπτει ακριβώς μία ακμή από τον γράφο κάθε χρήστη (leave-one-out strategy), με σκοπό το μοντέλο να την προβλέψει κατά την εκπαίδευσή του, μια διαδικασία που περιγράφεται στο paper της Wyze αλλά δεν υλοποιείται. Αντίστοιχα, το negative sampling περιορίζεται σε μία μόνο τεχνητή (ψευδή) ακμή ανά γράφο για να εξισορροπήσει την μία πραγματική που αφαιρέθηκε.

Επιπλέον, για την επιτάχυνση και σταθεροποίηση της σύγκλισης, ενσωματώνεται ένας δυναμικός ρυθμός μάθησης (dynamic learning rate) [45], ο οποίος αναπροσαρμόζεται βάσει του validation loss. Η συνάρτηση σφάλματος BCE είναι επίσης προσαρμοσμένη αναλυτικά (με απευθείας χρήση λογαρίθμων) ώστε να λαμβάνει υπόψη όλες τις πιθανές κατηγορίες των ακμών, αξιοποιώντας τα προαναφερθέντα edge embeddings. Κατά την φάση της αξιολόγησης, το σύστημα παράγει όλους τους πιθανούς συνδυασμούς κανόνων μεταξύ των διαθέσιμων συσκευών (πλήρεις γράφοι) [39] και υπολογίζει την πιθανότητά τους, κάτι που καθιστά τον εντοπισμό της κρυμμένης ακμής πολύ πιο δύσκολο, αλλά ταυτόχρονα απόλυτα ρεαλιστικό.

Τέλος, η κύρια μετρική αξιολόγησης δεν είναι το Mean Rank, αλλά το αντίστροφό του (Mean Reciprocal Rank, MRR) [46], το οποίο έχει την μαθηματική ιδιότητα να εφαρμόζει αυστηρότερη ποινή σε μοντέλα που κατατάσσουν τον πραγματικό κανόνα χαμηλά

ΚΕΦ. 3. Περιγραφή του προβλήματος

στη λίστα των προτάσεων, αναγκάζοντας το δίκτυο να δώσει προτεραιότητα στην εύρεσή του. Οι παραπάνω βελτιστοποιήσεις συμβάλλουν στην αύξηση της ταχύτητας ή της απόδοσης του μοντέλου, όμως δημιουργούν και μια πιο στιβαρή βάση για την αξιολόγησή του.

Η θεμελιώδης αδυναμία της υλοποίησης αυτής έγκειται ωστόσο στην centralized φύση της. Όπως έχει αναδειχθεί και στις προηγούμενες Ενότητες, ένας από τους σημαντικότερους στόχους του διαγωνισμού αλλά και των πραγματικών IoT συστημάτων είναι η διασφάλιση της προστασίας των προσωπικών δεδομένων των χρηστών. Για να επιτευχθεί αυτός ο σκοπός, είναι απαραίτητη η χρήση ενός federated περιβάλλοντος. Η παρούσα διπλωματική εργασία γεφυρώνει αυτό ακριβώς το χάσμα: απομονώνει τις εξαιρετικές αρχιτεκτονικές βελτιστοποιήσεις της δεύτερης θέσης, εννοχώνοντάς τις όμως σε ένα federated πλαίσιο.

Κεφάλαιο 4

Μεθοδολογία

4.1 Επισκόπηση του συστήματος

4.1.1 Στόχος της υλοποίησης

Η παρούσα εργασία επικεντρώνεται στη δημιουργία ενός federated μοντέλου για την επίλυση του προβλήματος της σύστασης κανόνων. Αξιοποιεί τα δεδομένα που παρείχε η Wyze στον διαγωνισμό της, σε μορφή δύο ζευγών αρχείων CSV: το πρώτο περιγράφει τις συσκευές κάθε χρήστη και το δεύτερο τους κανόνες μεταξύ τους. Η φύση και οι ιδιαιτερότητες των δεδομένων αναλύονται εκτενέστερα στην [Ενότητα 5.2](#). Στόχος της υλοποίησης είναι να καταδείξει την αντιστάθμιση μεταξύ ιδιωτικότητας και επίδοσης, με συμπληρωματικό στόχο μια ανταγωνιστική επίδοση σε σχέση με τη δεύτερη θέση του διαγωνισμού.

4.1.2 Ανάπτυξη των μοντέλων

Η ανάπτυξη της τελικής υλοποίησης ακολούθησε μια επαναληπτική διαδικασία, η οποία διακρίνεται σε τρεις εκδόσεις:

- Η πρώτη έκδοση (v1) υλοποιεί έναν βασικό federated αλγόριθμο, βασισμένο στη δημοσίευση της Wyze, χωρίς τα edge-type embeddings του μοντέλου της δεύτερης θέσης. Στόχος της είναι η επιβεβαίωση της λειτουργικότητας του federation και η εξαγωγή baseline αποτελεσμάτων. Συμπληρωματικά, αναπτύχθηκε μια βοηθητική συνάρτηση προεπεξεργασίας, ύστερα από τον εντοπισμό ελλείψεων και ασυνεπειών στο σύνολο δεδομένων της Wyze ([Ενότητα 4.2.1](#)).
- Η δεύτερη έκδοση (v2) εισάγει edge-type embeddings, ακολουθώντας πιστά την υλοποίηση της δεύτερης θέσης. Όπως διασαφηνίζεται στην [Ενότητα 4.3](#), πρόκειται για «pseudo-embeddings», καθώς το ίδιο το μοντέλο δεν υποστηρίζει πραγματικά embeddings. Στόχος της είναι η άμεση, «ένα προς ένα» σύγκριση δύο πανομοιότυπων μοντέλων, με μοναδική διαφοροποίηση την federated ενορχήστρωση.

- Η τρίτη έκδοση (v3) στηρίζεται στις βελτιώσεις της προηγούμενης και τις επαν-ξάνει, εισάγοντας πραγματικά edge-type embeddings και έναν βελτιωμένο relational decoder, καθώς και μια εναλλακτική συνάρτηση σφάλματος. (Ενότητα 4.4). Στόχος της είναι η βελτιστοποίηση του μοντέλου και η αναζήτηση αποδοτικότερης λύσης στο πρόβλημα. Συνοδεύεται από ablation studies υπερ-παραμέτρων, με σκοπό τον εντοπισμό των βέλτιστων συνθηκών εκπαίδευσης.

4.1.3 Δομή του κώδικα

Για την εκπαίδευση όλων των μοντέλων σε federated περιβάλλον χρησιμοποιήθηκε το Flower [47, 48], μια βιβλιοθήκη της Python για την προσομοίωση και την ενορχήστρωση federated υλοποιήσεων. Περισσότερες πληροφορίες για τη βιβλιοθήκη, καθώς και για τα υπόλοιπα εργαλεία των προσομοιώσεων, παρατίθενται στην Ενότητα 5.1.2. Με στόχο να εναρμονιστεί με τη δομή λειτουργίας του framework, ο κώδικας της παρούσας εργασίας οργανώνεται σε επτά διακριτά αρχεία:

- Στο `dataset.py` βρίσκονται οι βοηθητικές συναρτήσεις για την αρχικοποίηση του συνόλου δεδομένων, το φιλτράρισμα και τον καθαρισμό του, τη δημιουργία του λεξιλογίου συσκευών και κανόνων, και τη μετατροπή του σε μορφή γράφων.
- Στο `server_app.py` ορίζεται ο `server`, μαζί με τις συναρτήσεις `aggregation` και κεντρικής αξιολόγησης.
- Στο `client_app.py` ορίζονται οι `clients`, μαζί με τη συνάρτηση `fit` για την τοπική εκπαίδευση και βοηθητικές συναρτήσεις για τη λήψη και αποστολή των βαρών από και προς τον `server`.
- Στο `model.py` ορίζονται τα διαφορετικά μοντέλα που εκπαιδεύουν οι `clients`.
- Στο `task.py` περιέχονται οι συναρτήσεις για την εφαρμογή `leave-one-out` και `negative sampling`, καθώς και η λογική ενορχήστρωσης της τοπικής εκπαίδευσης.
- Στο `pyproject.toml` ορίζονται όλες οι υπερπαραμέτροι εκπαίδευσης (αριθμός `clients`, `local epochs`, στρατηγική συνάθροισης, `optimizer` κ.ά.).
- Στο `results_logger.py` βρίσκονται βοηθητικές συναρτήσεις για την καταγραφή των μετρικών ενός `run` και την δημιουργία `checkpoints` με τα καλύτερα μοντέλα.

Και οι τρεις εκδόσεις ακολουθούν αυτή τη δομή. Τα πειράματα προκύπτουν εκτελώντας το ίδιο πρόγραμμα με διαφορετικές παραμέτρους. Ο πλήρης κώδικας της εργασίας είναι διαθέσιμος στο [49].

4.2 Πρώτη έκδοση (v1)

4.2.1 Προεπεξεργασία δεδομένων

Τα δεδομένα του διαγωνισμού προέρχονται από ένα ιδιωτικό σύνολο της Wyze, το οποίο η εταιρεία ανωνυμοποίησε [2] και διέθεσε σε δύο ζεύγη αρχείων (train και test), που αφορούν τις συσκευές των χρηστών (train_device.csv, test_device.csv) και τους μεταξύ τους κανόνες (train_rule.csv, test_rule.csv) αποσπάσματα των οποίων παρουσιάζονται στους Πίνακες 4.1 και 4.2:

- `train_device.csv`: Περιέχει τις συσκευές όλων των χρηστών. Αποτελείται από τρεις στήλες: η πρώτη περιέχει ένα μοναδικό αναγνωριστικό (ID) για κάθε χρήστη (π.χ. 115535), η δεύτερη ένα μοναδικό αναγνωριστικό για κάθε συσκευή κάθε χρήστη (π.χ. 942835), και η τρίτη το μοντέλο της συσκευής (π.χ. Light). Έτσι, μια γραμμή διαβάζεται ως «ο χρήστης 115535 κατέχει τη συσκευή 942835, η οποία είναι λαμπτήρας». Κάθε συσκευή έχει το δικό της αναγνωριστικό ακόμη και αν είναι ίδιου τύπου με άλλες: αν ένας χρήστης διαθέτει τρεις πανομοιότυπες κάμερες, η καθεμία έχει ξεχωριστό ID αλλά κοινό μοντέλο «Camera»· αντίστοιχα, αν δύο χρήστες διαθέτουν το ίδιο μοντέλο, ο καθένας έχει το δικό του ID.
- `train_rule.csv`: Περιέχει τους κανόνες που έχει ορίσει κάθε χρήστης ανάμεσα στις συσκευές του. Αποτελείται από δέκα στήλες. Η πρώτη περιέχει το μοναδικό ID του χρήστη (π.χ. 257281), το οποίο αντιστοιχίζεται ένα προς ένα με εκείνα του `train_device.csv`. Η δεύτερη και η τρίτη περιέχουν το μοντέλο (π.χ. «ContactSensor») και το ID (π.χ. 559037) της συσκευής που πυροδοτεί τον κανόνα (trigger device). Η τέταρτη και η πέμπτη περιέχουν την κατάσταση (state) στην οποία πρέπει να βρίσκεται η συσκευή (π.χ. «Detects a person») και ένα μοναδικό ID για την κατάσταση αυτή (π.χ. 6). Η έκτη και η έβδομη περιέχουν τη δράση (action) που ενεργοποιείται, μαζί με το ID της, και η όγδοη και ένατη το μοντέλο και το ID της συσκευής που ενεργοποιείται (action device). Η τελευταία στήλη συγχωνεύει τα προηγούμενα IDs. Για παράδειγμα, η πρώτη γραμμή του Πίνακα 4.2 διαβάζεται ως: «ο χρήστης 289923 έχει ορίσει έναν κανόνα σύμ-

ΚΕΦ. 4. Μεθοδολογία

φωνα με τον οποίο, όταν η συσκευή 1507149 (κάμερα) εντοπίσει ένα κατοικίδιο (ID=7), τότε η συσκευή 1492326 (κάμερα) τίθεται σε λειτουργία (ID=41)».

Τα αρχεία `test_device.csv` και `test_rule.csv` έχουν ακριβώς την ίδια δομή με τα παραπάνω, αλλά αφορούν το σύνολο δεδομένων που χρησιμοποιείται για την αξιολόγηση του μοντέλου.

user_id	device_id	device_model
115535	107235	Lock
115535	511842	MotionSensor
115535	1793633	ContactSensor
115535	463524	ContactSensor
115535	572702	Light
115535	562426	MotionSensor
115535	120593	Camera
115535	1340294	Camera
115535	942835	Light
115535	1108491	Camera
...	...	...
289923	1507149	Camera
289923	1492326	Camera


Πίνακας 4.1: Απόσπασμα του `train_device.csv`: οι δέκα συσκευές του χρήστη 115535 και οι δύο του χρήστη 289923. Συσκευές ίδιου μοντέλου (δύο *Light*, πέντε *Camera*, δύο *MotionSensor*, δύο *ContactSensor*) έχουν διαφορετικά αναγνωριστικά.

Με στόχο την επιβεβαίωση της ορθότητας και της καθαρότητας του συνόλου δεδομένων, πραγματοποιήθηκε ανάλυσή του, η οποία απάντησε σε ερωτήματα όπως «πόσοι διαφορετικοί χρήστες υπάρχουν;», «πόσες συσκευές κατέχει κατά μέσο όρο κάθε χρήστης;» και «ποιος κανόνας εμφανίζεται συχνότερα;». Κυρίως όμως, οδήγησε στη διαπίστωση ότι αρκετές συσκευές συμμετέχουν σε κάποιον κανόνα στο `train_rule.csv`, ενώ απουσιάζουν από τη λίστα συσκευών του αντίστοιχου χρήστη στο `train_device.csv`, μένοντας πρακτικά αναξιοποίητες, ή «φαντάσματα» (ghosts).

Η υλοποίηση της δεύτερης θέσης απορρίπτει αυτές τις συσκευές, αποκλείοντας σημαντικό όγκο δεδομένων από την εκπαίδευση. Ύστερα από εκτενέστερη μελέτη, δια-

Trigger				Action				
user	device	id	state	id	action	id	device	id
289923	Camera	1507149	Detects a pet	7	Turn on the camera	41	Camera	1492326
289923	Camera	1507149	Detects a pet	7	Unmute Notifications	45	Cloud	1797174
257281	ContactSensor	1769589	Opens	25	Turn on	30	Light	265706
257281	MotionSensor	1521508	Detects motion	9	Turn on	30	Light	399694
257281	Camera	275358	Detects a person	6	Turn on for	34	Light	371957
257281	Switch	1752653	Double Press	12	Turn on	30	Plug	1327057

Πίνακας 4.2: Απόσπασμα του `train_rule.csv` (η τελευταία στήλη `rule`, που συνενώνει τα τέσσερα IDs, παραλείπεται). Η πρώτη γραμμή αντιστοιχεί στο παράδειγμα του κειμένου. Η δεύτερη δείχνει τη νοητή συσκευή *Cloud*, η οποία εμφανίζεται μόνο στους κανόνες. Οι κανόνες του χρήστη 289923 αντιστοιχίζονται στις συσκευές που εμφανίζονται στον Πίνακα 4.1.




Σχήμα 4.1: Παράδειγμα του γράφου του χρήστη 257281. Ο χρήστης κατέχει 8 συσκευές και 4 κανόνες μεταξύ τους. Στις τελευταίες 4 γραμμές του Πίν. 4.2 φαίνονται οι εγγραφές του.

πιστώθηκε ότι πρόκειται για έγκυρα δεδομένα που ακολουθούν τις ίδιες κατανομές με τις υπόλοιπες συσκευές και σχηματίζουν εξίσου έγκυρους κανόνες, και επομένως μπορούν να προσφέρουν χρήσιμη πληροφορία στην εκπαίδευση. Για τον λόγο αυτό, ει-σήχθη κατά το preprocessing η βοηθητική συνάρτηση `resurrect_ghosts()`, η οποία προσθέτει τις συσκευές «φαντάσματα» στη λίστα συσκευών κάθε χρήστη. Σε πειρα-ματικό επίπεδο, η συνάρτηση μπορεί να απενεργοποιηθεί μέσω του αντίστοιχου flag ([Ενότητα 4.2.3](#)).

Πέρα από αυτή τη διαφοροποίηση, η προετοιμασία των δεδομένων δεν διαφέρει ου-σιαστικά από εκείνη της δεύτερης θέσης: τα αρχεία φορτώνονται από τοπικό φά-κελο ή απευθείας από τη σελίδα του διαγωνισμού στο HuggingFace, παράγεται το λεξιλόγιο όλων των μοναδικών τύπων συσκευών και κανόνων, φιλτράρονται οι κανό-νες που εμφανίζονται λιγότερες από έναν καθορισμένο αριθμό φορών, ώστε το μο-ντέλο να εκπαιδευτεί σε συχνά εμφανιζόμενα μοτίβα, αντιστοιχίζονται οι συσκευές «φαντάσματα» και, τέλος, τα δεδομένα μετατρέπονται σε γράφους (PyG tensors).

4.2.2 Μοντέλα μηχανικής μάθησης

Τα μοντέλα της πρώτης έκδοσης ταυτίζονται με εκείνα της υλοποίησης της Wyze. Όπως αναφέρθηκε στην [Ενότητα 3.4](#), για το node embedding χρησιμοποιείται ένα GraphSAGE [28] με δύο επίπεδα SAGEConv, mean aggregation και ενεργοποίηση ReLU μετά το πρώτο επίπεδο, ενώ για το link prediction ένα MLP δύο επιπέδων.



Σχήμα 4.2: Pipeline πρώτης έκδοσης: Το encoding των γράφων γίνεται μέσω του GraphSAGE, ενώ το decoding μέσω ενός MLP.

4.2.3 Ενορχήστρωση

Όλες οι παράμετροι της πειραματικής διαδικασίας ρυθμίζονται κατά την κλήση της κύριας συνάρτησης της προσομοίωσης: ο ελάχιστος επιτρεπόμενος αριθμός εμφα-


νίσεων ανά κανόνα, η ενεργοποίηση ή μη της επαναφοράς «φαντασμάτων», ο ρυθμός μάθησης, ο αριθμός των local epochs, η στρατηγική συνάθροισης, ο τοπικός optimizer κ.ά. Με την κλήση της συνάρτησης αρχικοποιείται το περιβάλλον του Flower, το οποίο με τη σειρά του αρχικοποιεί τον server και τους clients, φορτώνει το σύνολο δεδομένων στη μνήμη και ενορχηστρώνει την εκπαίδευση. Σε κάθε γύρο υπολογίζονται οι μετρικές, οι οποίες συνοψίζονται στο τέλος της εκπαίδευσης.

4.3 Δεύτερη έκδοση (v2)


Η δεύτερη έκδοση διαφοροποιείται από την πρώτη μόνο ως προς το μοντέλο που εκπαιδεύεται. Η διαχείριση των δεδομένων, οι υπερπαραμέτροι και η ενορχήστρωση της εκπαίδευσης παραμένουν ίδιες με πριν. Η υλοποίηση μιμείται εκείνη της δεύτερης θέσης, ενσωματώνοντας edge-type embeddings στους κόμβους των γράφων πριν από την είσοδό τους στο GraphSAGE. Όπως αναλύθηκε στις Ενότητες 3.4.2 και 3.5, η κωδικοποίηση του τύπου κάθε κανόνα εμπλουτίζει σημαντικά την πληροφορία που διαθέτει το δίκτυο και βελτιώνει τις επιδόσεις του μοντέλου. Για τον λόγο αυτό, η διαφοροποίηση αυτή μελετάται πειραματικά.

Συγκεκριμένα, πριν οι γράφοι φορτωθούν στο GraphSAGE, εισάγονται δύο πίνακες embeddings: ένας για την κατάσταση που πυροδοτεί τον κανόνα (trigger state) και ένας για τη δράση που ενεργοποιείται (action). Για κάθε ακμή του γράφου, το trigger embedding συνενώνεται μέσω concatenation με τον κόμβο trigger device και το action embedding με τον κόμβο του action device.

Η προσέγγιση αυτή χαρακτηρίζεται ως pseudo-embeddings» γιατί η πληροφορία του τύπου των κανόνων δεν αξιοποιείται εγγενώς κατά το message passing. Το GraphSAGE δεν έχει την αρχιτεκτονική δυνατότητα να περάσει το vector του τύπου κάθε ακμής ξεχωριστά μέσα από τα layers του. Η δεύτερη έκδοση προσπαθεί να προσεγγίσει αυτή την λειτουργικότητα μέσω του aggregation και concatenation αυτής της πληροφορίας στους ίδιους τους κόμβους πριν από το GNN. Εμπλουτίζει δηλαδή το feature vector κάθε κόμβου (που καθορίζει τι είδους συσκευή είναι) με το vector του τύπου των συνδέσεών του (που καθορίζει πώς συνδέεται με άλλες συσκευές). Το ίδιο το GNN εξακολουθεί να αντιμετωπίζει τις ακμές ως απλές συνδέσεις χωρίς τύπο, έχοντας όμως μία εικόνα για το ποιος θα μπορούσε να είναι αυτός μέσω των εμπλουτισμένων feature vectors των κόμβων. Πρόκειται δηλαδή για μια προσέγγιση των πραγματικών edge embeddings, τα οποία υλοποιούνται στην τρίτη έκδοση (Ενότητα 4.4). Το Σχήμα 4.3 αναδεικνύει αυτή την διαφοροποίηση.



Σχήμα 4.3: Pseudo-embeddings: οι αναπαραστάσεις των τύπων ακμών (πάνω), π.χ. [0,1,0] για το trigger «ανίχνευση προσώπου» και [0,0,1] για το action «άναψε», μετατρέπονται σε δύο embeddings τεσσάρων διαστάσεων (μέση) και γίνονται concatenate (κάτω) με τους τύπους των συσκευών. Στο παράδειγμα όλες οι συσκευές είναι είτε sources είτε destinations, αλλά μία συσκευή μπορεί να είναι και τα δύο.



Σχήμα 4.4: Pipeline δεύτερης έκδοσης: Πριν την είσοδο στο GraphSAGE, οι τύποι των ακμών ενσωματώνονται στους κόμβους μέσω των pseudo-embeddings.

4.4 Τρίτη έκδοση (v3)


Η τρίτη έκδοση (v3) αποτελεί μια απόπειρα βελτιστοποίησης του συστήματος σε όλους τους τομείς του. Εξετάζει διαφορετικές αρχιτεκτονικές τόσο στην κωδικοποίηση της δομής των γράφων (CompGCN [50] αντί για GraphSAGE) όσο και στην αποκωδικοποίησή της και την πρόβλεψη ακμών (ComplEx [51] αντί για MLP). Επιπλέον, υλοποιεί μία διαφορετική συνάρτηση σφάλματος, προσαρμοσμένη στο πρόβλημα προς επίλυση [52].

4.4.1 CompGCN encoder

Όπως αναφέρθηκε στην [Ενότητα 4.3](#), η υλοποίηση της δεύτερης έκδοσης αξιοποιεί το GraphSAGE για τα embeddings των συσκευών των χρηστών (κόμβων), το οποίο ωστόσο δεν έχει την δυνατότητα να αναπαραστήσει τα εξίσου σημαντικά embeddings των κανόνων (ακμών). Τα embeddings αυτά προσεγγίστηκαν μέσω του aggregation και του concatenation των τύπων των ακμών στους κόμβους πριν το encoding του GraphSAGE. Η τρίτη έκδοση της υλοποίησης αλλάζει την αρχιτεκτονική του encoding, αξιοποιώντας πλέον πραγματικά τους τύπους των κανόνων, μέσω του CompGCN ([Σχήμα 4.6](#)).

Το CompGCN είναι ένα δίκτυο GNN εξειδικευμένο στην αναπαράσταση multi-relational γράφων [53], δηλαδή γράφων που υποστηρίζουν πολλαπλούς τύπους ακμών, όπως αυτό του [Σχήμα 4.5](#). Η βασική ιδέα είναι ότι κατά την διαδικασία του message passing από έναν γείτονα, δεν μεταφέρεται μόνο το feature vector του, αλλά η σύνθεσή του με τον τύπο της ακμής που τον συνδέει με τον υπό ανάλυση κόμβο (στην παρούσα εργασία πολλαπλασιασμός κατά στοιχείο) [50]. Έτσι, το δίκτυο αφομοιώνει πραγματικά μέσα στην αρχιτεκτονική του τους τύπους των κανόνων που συνδέουν τις συσκευές, και όχι τεχνητά μέσω ενός απλού pre-processing σταδίου.

Επιπλέον, η αρχιτεκτονική του CompGCN αποθηκεύει εγγενώς τις αναπαραστάσεις των τύπων των κανόνων σε κάθε layer της, γεγονός που διευκολύνει το επόμενο στάδιο της διαδικασίας: το decoding.




Σχήμα 4.5: Παράδειγμα multi-relational γράφου: οι κόμβοι συνδέονται με 4 διαφορετικούς τύπους ακμών («έγραψε το», «σκηνοθέτησε το», «παίζει στο», και «ανήκει στο είδος»).

4.4.2 ComplEx decoder

Μέχρι στιγμής, το δεύτερο στάδιο του μοντέλου, αυτό της πρόβλεψης μιας νέας ακμής, αποτελούνταν από ένα απλό MLP που προσπαθούσε να μάθει μία γενικευμένη συνάρτηση ελαχιστοποίησης του σφάλματος πρόβλεψης (Ενότητα 4.3). Στην τρίτη έκδοση αντικαθίσταται από το ComplEx, έναν εξειδικευμένο relational decoder, ο οποίος βαθμολογεί απευθείας κάθε τριπλέτα συσκευή-κανόνας-συσκευή μέσω ενός τριγωνικού γινομένου σε μιγαδικό διανυσματικό χώρο (Σχήμα 4.7).

Η ειδοποιός διαφορά σε σχέση με το MLP είναι ότι το ComplEx ενσωματώνει τους κανόνες στο ίδιο το score μέσω του embedding του, αξιολογώντας άμεσα κάθε τριπλέτα, ενώ το MLP δεν μπορεί παρά μόνο να τους κάνει concatenate στην γενικευμένη softmax συνάρτησή του.




Σχήμα 4.6: Η αρχιτεκτονική του CompGCN: κάθε μήνυμα συνθέτει την αναπαράσταση του γείτονα με εκείνη του τύπου της ακμής που τους συνδέει μέσω της συνάρτησης σύνθεσης ϕ [50].

Η επιλογή ενός μιγαδικού χώρου ενέχει το σημαντικό πλεονέκτημα της δυνατότητας αναπαράστασης ασύμμετρων σχέσεων: ο κανόνας «η συσκευή A πυροδοτεί την B» είναι προφανώς εννοιολογικά διαφορετικός από την αντίστροφό του, και το ComplEx διαχωρίζει αυτά τα δύο σενάρια, σε αντίθεση με άλλους decoders όπως ο DistMult [54], επιτρέποντας έτσι μία στιβαρή αξιολόγηση [51].

4.4.3 InfoNCE loss και hard negative sampling

Τέλος, η τρίτη έκδοση εισάγει μία νέα συνάρτηση σφάλματος κατά την διαδικασία του training. Η BCE (Ενότητα 4.3) αντικαθίσταται από την InfoNCE (Σχήμα 4.9), που στόχο έχει να αναγνωρίσει την επιθυμητή (θετική) ακμή ανάμεσα σε k αρνητικές, μελετώντας την διαφοροποίηση στην στοχαστική πληροφορία που περιέχουν ως τυχαίες μεταβλητές (συγκεκριμένα, αποτελεί μια συνάρτηση προσέγγισης του Mutual Information [52, 55] αυτών των τυχαίων μεταβλητών). Η InfoNCE αποτελεί ειδική περίπτωση της CCE (Categorical Cross-Entropy loss), η οποία παρουσιάζει στενότερο θεωρητικό κάτω φράγμα MRR από την BCE [56] και έτσι μπορεί δυνητικά να αποδώσει καλύτερα αποτελέσματα με την κατάλληλη παραμετροποίηση. Στην παρούσα εργασία, κατόπιν ablation της παραμέτρου k (βλ. Ενότητα 5.5.2), διαπιστώθηκε ότι η τιμή $k = 64$ για τα negative samples αποδίδει ικανοποιητικά αποτελέσματα.




Σχήμα 4.7: Το ComplEx decoder βαθμολογεί μια τριπλέτα (h, r, t) , όπου h (head) = trigger device, r (relation) = rule, t (tail) = action device, με το τριγωναμικό γινόμενο $\text{Re}(\langle h, r, \bar{t} \rangle)$ στο μιγαδικό επίπεδο, όπου $\bar{t}$ το συζυγές του tail. Επειδή η εναλλαγή των ρόλων head/tail μετακινεί την συζυγία, το score που ανατίθεται στον κανόνα « $h \rightarrow t$ » $s = \text{Re}(\langle h, r, \bar{t} \rangle)$ (αριστερά) είναι διαφορετικό από αυτό που ανατίθεται στον κανόνα « $t \rightarrow h$ » $s = \text{Re}(\langle t, r, \bar{h} \rangle)$. Αυτή η ιδιότητα επιτρέπει την αναπαράσταση κατευθυνόμενων κανόνων.

Για να γίνει ακόμη πιο αποδοτικός ο διαχωρισμός μεταξύ της θεμιτής ακμής και των αρνητικών, εισάγονται «hard negatives» (Σχήμα 4.8) στον γράφο κάθε χρήστη, δηλαδή ακμές που ενώνουν τις ίδιες συσκευές με την πραγματική, με μόνη διαφορά τον τύπο του κανόνα που αναπαριστούν. Αυτές οι ακμές είναι πιο δύσκολο να κατηγοριοποιηθούν ως εσφαλμένες, γιατί είναι πιο αληθοφανείς (εννοιολογικά δηλαδή πιο κοντά στην πραγματική ακμή). Για παράδειγμα, ο κανόνας «κάμερα ανιχνεύει κίνηση $\rightarrow$ φως σβήνει» είναι ένας πολύ κοντινός κανόνας στον πραγματικό «κάμερα ανιχνεύει κίνηση $\rightarrow$ φως ανάβει» σε σχέση με τον «κάμερα ανιχνεύει κίνηση $\rightarrow$ ηχείο παίζει μουσική». Το ποσοστό των hard negatives είναι παραμετροποιήσιμο, και επέφερε τα καλύτερα αποτελέσματα όταν ήταν ίσο με το 50% των συνολικών αρνητικών ακμών (βλ. Ενότητα 5.5.2).


Στο Σχήμα 4.9 φαίνεται η λειτουργία της InfoNCE σε δύο τυχαία χρονικά σημεία της εκπαίδευσης, καθώς και η επίδραση των hard negatives. Αρχικά, τα hard negatives έχουν μεγαλύτερες πιθανότητες να τοποθετηθούν ψηλότερα από την πραγματική θετική ακμή από το ComplEx, λόγω της δυσκολίας διαφοροποίησης μεταξύ των δύο. Η

softmax της InfoNCE εφαρμόζει έντονη ποινή στις ακμές που βρίσκονται πάνω από την θετική (εδώ, το hard negative s_2^-), ενώ η συνεισφορά των ακμών που βρίσκονται κάτω από την θετική (εδώ, τα soft negatives s_1^- και s_3^-), είναι πολύ μικρή.




Σχήμα 4.10: Pipeline τρίτης έκδοσης: Το GraphSAGE αντικαθίσταται από το CompGCN για το encoding, ενώ το MLP αντικαθίσταται από το ComplEx για το decoding.


Ο συνδυασμός των τριών αυτών αλλαγών (CompGCN + ComplEx + InfoNCE με hard negatives) αποτελεί την τελική διαμόρφωση της υλοποίησης (Σχήμα 4.11), η αποτελεσματικότητα της οποίας περιγράφεται αναλυτικά στην Ενότητα 5.5.



Σχήμα 4.8: Hard negatives: Πάνω φαίνεται η πραγματική (θετική) ακμή προς μελέτη ($A \rightarrow B$). Κάτω αριστερά εικονίζονται δύο **απλά (soft) negatives**: το μπλε ($\Delta \rightarrow E$) έχει διαφορετικό source κόμβο (Δ αντί A) και destination κόμβο (E αντί B), ενώ το πράσινο ($A \rightarrow \Gamma$) έχει ίδιο source κόμβο (A). Κάτω δεξιά εικονίζεται ένα **hard negative**: η νέα ακμή έχει **κοινό** τόσο τον source κόμβο (A) όσο και τον destination (B), με μόνη διαφορά σε σχέση με την θετική ακμή τον **τύπο** της ακμής («ανίχνευση προσώπου $\rightarrow$ σβήσε» αντί «ανίχνευση κίνησης $\rightarrow$ άναψε»). Πληροί έτσι τις δύο προϋποθέσεις των hard negatives: (α) έχει κοινό ζεύγος (src, dst) και διαφορετικό τύπο ακμής, και (β) δεν αποτελεί προϋπάρχουσα ακμή στον γράφο του χρήστη (ο αρχικός γράφος πάνω έχει μόνο μία ακμή από το A στο B , την υπό εξέταση).



Σχήμα 4.9: InfoNCE loss σε δύο γύρους εκπαίδευσης: **Πάνω (γύρος 75):** το ComplEx μετατρέπει το positive edge $\{C, [1,5], A\}$ σε ένα σκορ s^+ , και τα negatives $\{D, [5,1], B\}$, $\{C, [3,4], A\}$ και $\{E, [8,2], F\}$ σε s_1^- , s_2^- και s_3^- αντίστοιχα, στον άξονα των πραγματικών. Η InfoNCE υπολογίζει το softmax τους (θετική στον αριθμητή, θετική συν άθροισμα αρνητικών στον παρονομαστή), πιέζοντας την θετική ακμή πάνω από όλες τις αρνητικές. **Κάτω (γύρος 80):** το CompGCN έχει αναμορφώσει τα embeddings ώστε η θετική να ξεπερνά πλέον και το hard negative s_2^- που προηγουμένως προηγούνταν.



Σχήμα 4.11: Συνολική αρχιτεκτονική της τελικής υλοποίησης (v3), από τον γράφο του χρήστη έως την απώλεια. Ο CompGCN encoder παράγει embeddings των κόμβων και των τύπων ακμών (πάνω), από τα οποία συναρμολογείται μια τριπλέτα (h, r, t) (κάτω δεξιά). Στην συνέχεια ο ComplEx decoder μετατρέπει κάθε τριπλέτα σε ένα βαθμωτό score $s = \text{Re}(\langle h, r, \bar{t} \rangle)$ (κάτω αριστερά). Η InfoNCE συγκρίνει το score της θετικής ακμής με εκείνα K αρνητικών, και το gradient της αναμορφώνει τα embeddings.

Κεφάλαιο 5

Πειράματα

5.1 Τεχνικές προδιαγραφές και εργαλεία

5.1.1 Απαιτήσεις συστήματος

Όλα τα πειράματα της παρούσας εργασίας διενεργήθηκαν σε λειτουργικό σύστημα Ubuntu 22.04.5 LTS, με δύο επεξεργαστές Intel Xeon Silver 4210R (10 πυρήνων στα 2,4 GHz έκαστος), μία κάρτα γραφικών NVIDIA RTX A6000 με 48 GB μνήμης GDDR6, και 64 GB (4×16 GB) μνήμης RAM DDR4. Τα πειράματα εκτελέστηκαν σε περιβάλλον προσομοίωσης ομοσπονδιακής μάθησης και όχι σε πραγματικές edge συσκευές και ως εκ τούτου, κατέστη απαραίτητη η χρήση ενός μηχανήματος μεγάλης υπολογιστικής ισχύος, ικανού να προσομοιώσει ταυτόχρονα χιλιάδες χρήστες. Σε ένα πραγματικό περιβάλλον, η τοπική εκπαίδευση κάθε client θα μπορούσε να εκτελεστεί βιώσιμα σε edge συσκευές, καθώς το υπολογιστικό της κόστος βρίσκεται εντός των ορίων των περισσότερων σύγχρονων συσκευών.

5.1.2 Βιβλιοθήκες και εργαλεία

Ο κώδικας της εργασίας γράφτηκε σε γλώσσα Python και στηρίχθηκε κυρίως στις βιβλιοθήκες Flower [47, 48], PyTorch [57, 58] και PyTorch Geometric [40, 41].

Το Flower αποτελεί ένα από τα πλέον διαδεδομένα και ολοκληρωμένα open-source frameworks για την ενορχήστρωση ομοσπονδιακής μάθησης, τόσο σε ερευνητικό όσο και σε εμπορικό επίπεδο. Χρησιμοποιείται ως βάση για όλα τα στάδια της προσομοίωσης: από την αρχικοποίηση του server και των clients και τη δέσμευση μνήμης για τη μεταφορά πληροφορίας μεταξύ τους, μέχρι τις συναρτήσεις για aggregation, τους optimizers και τον διαμοιρασμό του συνόλου δεδομένων στους clients. Χωρίς αυτό, η ενορχήστρωση του ομοσπονδιακού περιβάλλοντος θα έπρεπε να υλοποιηθεί χειροκίνητα, εγχείρημα δύσκολο, χρονοβόρο και δευτερεύουσας σημασίας για τους σκοπούς της εργασίας.

Σε παρόμοιο πνεύμα αξιοποιούνται οι βιβλιοθήκες PyTorch και PyTorch Geometric

(PyG). Η πρώτη είναι μία από τις θεμελιώδεις βιβλιοθήκες για προβλήματα μηχανικής μάθησης, καθώς παρέχει κλάσεις, βοηθητικές συναρτήσεις και δομές δεδομένων για τη δημιουργία και εκτέλεση μοντέλων, τόσο σειριακά σε επεξεργαστή όσο και παράλληλα σε GPU. Η δεύτερη αποτελεί επέκταση της πρώτης, εξειδικευμένη στη δημιουργία μοντέλων GNN για βαθιά μάθηση σε γράφους.

Συμπληρωματικά χρησιμοποιήθηκαν οι βιβλιοθήκες NumPy [59, 60] και Pandas [43, 44] για μαθηματικούς υπολογισμούς και διαχείριση δεδομένων, καθώς και η tqdm [61] για την παρακολούθηση της προόδου της εκπαίδευσης, χωρίς ωστόσο να συνεισφέρουν σε κάποια κύρια λειτουργία της υλοποίησης.

5.2 Ανάλυση δεδομένων

Όπως περιγράφηκε στην [Ενότητα 4.2.1](#), το σύνολο δεδομένων της Wyze διατίθεται σε δύο ζεύγη αρχείων CSV: ένα για την εκπαίδευση (train) και ένα για την αξιολόγηση (test). Κάθε ζεύγος περιλαμβάνει ένα αρχείο συσκευών και ένα αρχείο κανόνων. Στην παρούσα Ενότητα παρουσιάζεται μια αναλυτική περιγραφή των δεδομένων, από την αρχική μορφή τους έως τις τελικές κατανομές μετά την επεξεργασία και το φιλτράρισμα. Όλα τα μεγέθη που ακολουθούν είναι πλήρως reproducible μέσω του κώδικα της εργασίας [49].

5.2.1 Αρχικά δεδομένα

Στην ακατέργαστη μορφή τους, τα δύο σύνολα έχουν το μέγεθος που παρουσιάζεται στον Πίνακα 5.1. Αξίζει να σημειωθεί ότι τα δύο αρχεία κάθε συνόλου αναφέρονται στους ίδιους ακριβώς χρήστες: το πλήθος των μοναδικών χρηστών στο αρχείο συσκευών ταυτίζεται με εκείνο στο αρχείο κανόνων.

Σύνολο δεδομένων	Πλήθος χρηστών	Πλήθος συσκευών	Πλήθος κανόνων
Train set	272.664	1.354.098	852.072
Test set	13.557	110.207	60.745

Πίνακας 5.1: Μέγεθος των συνόλων εκπαίδευσης και αξιολόγησης στην αρχική μορφή της Wyze.

5.2.2 Λεξιλόγιο

Από το σύνολο εκπαίδευσης εξάγεται το λεξιλόγιο όλων των μοναδικών τύπων συσκευών και κανόνων. Τα διαφορετικά μοντέλα συσκευών ανέρχονται σε 16 (15 πραγματικές συσκευές συν το Cloud, που αφορά οποιαδήποτε διασύνδεση με τους servers της Wyze). Ο αριθμός αυτός ορίζει τη διάσταση των one-hot features κάθε κόμβου. Οι διαφορετικοί τύποι κανόνων της μορφής «trigger-action» ανέρχονται σε 791 συνολικά, ωστόσο μετά το φιλτράρισμα των σπάνιων κανόνων (βλ. [Ενότητα 5.2.3](#)) διατηρούνται 552, οι οποίοι αποτελούν και τις κλάσεις εξόδου του link predictor. Τέλος, οι μοναδικές καταστάσεις πυροδότησης (trigger states) ανέρχονται σε 45 και οι δράσεις (actions) σε 47. Τα δύο αυτά μεγέθη ορίζουν τις διαστάσεις των αντίστοιχων πινάκων embeddings στις εκδόσεις v2 και v3.

5.2.3 Φιλτράρισμα και επαναφορά «φαντασμάτων»

Κατά την διαδικασία του preprocessing συμβαίνει μια σειρά διαδοχικών σταδίων φιλτραρίσματος, τα οποία απεικονίζονται στο [Σχήμα 5.1](#). Αρχικά, απορρίπτονται οι κανόνες που εμφανίζονται λιγότερες από 20 φορές συνολικά, ώστε το μοντέλο να εκπαιδευτεί σε συχνά εμφανιζόμενα μοτίβα και όχι σε εξαιρέσεις. Το φιλτράρισμα αυτό γίνεται και στην υλοποίηση της δεύτερης θέσης, με τον αριθμό 20 να είναι καθαρά ενδεικτικός. Το βήμα αυτό αφαιρεί μόλις το 0,3% των κανόνων (από 852.072 σε 849.618 στο train set). Στη συνέχεια διατηρούνται μόνο οι χρήστες που διαθέτουν τουλάχιστον μία συσκευή και έναν έγκυρο κανόνα (272.397 στην εκπαίδευση), ώστε να απορριφθούν χρήστες με κενούς γράφους. Τέλος, για την εκπαίδευση απαιτούνται τουλάχιστον δύο κανόνες ανά χρήστη ώστε η διαδικασία leave-one-out να αφήνει πάντοτε τουλάχιστον μία ακμή ως context αξιολόγησης, καταλήγοντας σε 149.558 χρήστες. Το ίδιο φίλτρο στο test set δίνει 8.970 χρήστες με ≥ 2 κανόνες, οι οποίοι αποτελούν το σύνολο cold-start evaluation.


Κατά την ανάλυση των δεδομένων παρατηρήθηκε ότι αρκετές συσκευές συμμετέχουν σε κάποιον κανόνα, ενώ απουσιάζουν από τη λίστα συσκευών του αντίστοιχου χρήστη (οι συσκευές «φαντάσματα» που εισήχθησαν στην [Ενότητα 4.2.1](#)). Η συνάρτηση `resurrect_ghosts()` τις επαναφέρει. Η επίδρασή της στο train set μετά το φιλτράρισμα συνοψίζεται στον Πίνακα [5.2](#): η επαναφορά προσθέτει 95.402 ακμές (αύξηση 15,1%) και διασώζει 8.975 χρήστες που διαφορετικά θα κατέληγαν με κενό γράφο. Αξίζει να αναφερθεί ότι το 96% των επαναφερόμενων ακμών (91.728) αφορά το Cloud (ειδοποιήσεις, χρονοπρογραμματισμοί κ.ά.) που εξ ορισμού δεν εμφανίζεται στο αρχείο συσκευών (βλ. [Ενότητα 5.2.2](#)). Συνολικά, το 12,6% όλων των ακμών του

ΚΕΦ. 5. Πειράματα

train set εμπλέκει τη συσκευή Cloud. Χωρίς την επαναφορά «φαντασμάτων», περίπου μία στις οκτώ ακμές θα ήταν μη αναπαραστάσιμη.

Μέγεθος (μετά το φιλτράρισμα)	Χωρίς resurrection	Με resurrection	Διαφορά
Ακμές train set	631.377	726.779	+95.402
Μη κενοί γράφοι	140.583	149.558	+8.975
Χρήστες με ≥ 2 ακμές	123.991	149.558	+25.567

Πίνακας 5.2: Επίδραση της συνάρτησης `resurrect_ghosts()` στο train set.



Σχήμα 5.1: Διαδικασία φιλτραρίσματος χρηστών του train set, από τα raw data στα τελικά δεδομένα εκπαίδευσης.

5.2.4 Data splits και sampling

Η εκπαίδευση στην παρούσα εργασία γίνεται στο πλήρες σύνολο των 149.558 χρηστών του train set και η αξιολόγηση γίνεται στο ξεχωριστό αρχείο αξιολόγησης που παρείχε η Wyze (13.544 συνολικοί χρήστες, εκ των οποίων 8.970 με ≥ 2 κανόνες). Πρόκειται για cold start αξιολόγηση, καθώς οι χρήστες και οι συσκευές του συνόλου αξιολόγησης δεν εμφανίζονται καθόλου στην εκπαίδευση. Αντιθέτως, η υλοποίηση

της δεύτερης θέσης χωρίζει το σύνολο εκπαίδευσής της σε αναλογία 80/10/10, εκπαιδεύοντας σε ~119.646 χρήστες και αξιολογώντας σε ένα εσωτερικό, ομοιογενές υποσύνολο ~14.860 χρηστών, μια ουσιώδη διαφορά στο πρωτόκολλο αξιολόγησης που αναλύεται στην [Ενότητα 5.4](#).


Για το σενάριο της «καθαρής» cross-device ενορχήστρωσης (περισσότερα στην [Ενότητα 5.3](#)), όπου κάθε client αντιστοιχεί σε έναν μόνο χρήστη, το σύνολο εκπαίδευσης υποδειγματοληπτείται σε 25.000 χρήστες χάριν αποδοτικότητας και προσομοίωσης ενός πραγματικού cross-device περιβάλλοντος. Τόσο αυτή η υποδειγματοληψία όσο και κάθε τυχαία επιλογή κατά το preprocessing (π.χ. ο διαμοιρασμός των χρηστών στους clients) βασίζονται σε σταθερό seed, εξασφαλίζοντας ότι κάθε εκτέλεση είναι reproducible και ότι διαφορετικά πειράματα εκπαιδεύονται στο ίδιο ακριβώς υποσύνολο χρηστών.

5.2.5 Κατανομές

Τα δεδομένα της Wyze χαρακτηρίζονται από έντονη αραιότητα και ετερογένεια, όπως αναλύθηκε θεωρητικά στην [Ενότητα 2.2.2](#). Ο [Πίνακας 5.3](#) και το [Σχήμα 5.2](#) ποσοτικοποιούν αυτή την ιδιότητα. Ο διάμεσος χρήστης έχει 3 συσκευές και έχει ορίσει 3 κανόνες, ενώ οι μέσοι όροι (6,19 και 4,86 αντίστοιχα) ανεβαίνουν λόγω μιας μακράς ουράς λίγων «ισχυρών» χρηστών που φτάνουν έως και 154 συσκευές και 446 κανόνες. Το 37,1% των χρηστών έχει ακριβώς τον ελάχιστο αριθμό των 2 κανόνων, το 77,7% έχει έως 5, και το 92,5% έως 10. Εξίσου ασύμμετρη είναι και η κατανομή των ίδιων των τύπων κανόνων: ο πιο δημοφιλής κανόνας εμφανίζεται 65.218 φορές, οι 10 πιο δημοφιλείς τύποι καλύπτουν το 49,8% όλων των ακμών, ενώ το 50% των πιο δημοφιλών τύπων καλύπτει το 98,5% των ακμών.

Μετρική (ανά χρήστη)	Μέσος όρος	Διάμεσος	≤ 5 (%)	≤ 10 (%)	Μέγιστο
Συσκευές	6,19	3	70,5	83,5	154
Κανόνες	4,86	3	77,7	92,5	446

Πίνακας 5.3: Κατανομές συσκευών και κανόνων ανά χρήστη (train set μετά το φιλτράρισμα). Και οι δύο άξονες παρουσιάζουν έντονη μακρά ουρά (μέσος όρος $\gg$ διάμεσος). Οι στήλες ≤ 5 και ≤ 10 δίνουν το ποσοστό των χρηστών με έως 5 και έως 10 συσκευές ή κανόνες αντίστοιχα.



Σχήμα 5.2: Κατανομές του πλήθους συσκευών (αριστερά) και κανόνων (δεξιά) ανά χρήστη, σε γραμμική (επάνω) και λογαριθμική (κάτω) κλίμακα συχνότητας. Ο άξονας x περιορίζεται στο 99^{o} εκατοστημόριο για ευκρίνεια. Η μακρά ουρά εκτείνεται πολύ πέρα από αυτό, έως 154 συσκευές και 446 κανόνες ανά χρήστη. Οι κατακόρυφες γραμμές σημειώνουν τη διάμεσο και τον μέσο όρο.


5.3 Τύποι ενορχήστρωσης

Ένας από τους κυριότερους στόχους της διπλωματικής είναι η κατάδειξη του κόστους που έχει στην αποδοτικότητα πρόβλεψης μία federated υλοποίηση. Για να αξιολογηθεί αυτό πειραματικά, μελετήθηκαν τέσσερα σενάρια ενορχήστρωσης, το καθένα με διαφορετικό βαθμό federation (βλ. [Ενότητα 2.2](#) για τον αρχιτεκτονικό διαχωρισμό μεταξύ cross-device και cross-silo εκπαίδευσης).

- **Centralized:** Αποτελεί το σημείο αναφοράς χωρίς ομοσπονδιακή μάθηση: ένας μοναδικός client κατέχει το σύνολο των δεδομένων όλων των χρηστών και εκπαιδεύει το μοντέλο κεντρικά. Δεν υπάρχει aggregation μεταξύ clients, και επομένως κανένα κόστος που να οφείλεται στην κατανομή των δεδομένων. Χρησιμοποιείται για να μετρηθεί το «κόστος» της ομοσπονδιακής μάθησης σε επίδοση.
- **Cross-silo:** Τα δεδομένα διαμοιράζονται σε λίγους (4) αξιόπιστους υπερκόμβους (silos), καθένας από τους οποίους κατέχει ένα μεγάλο, ισορροπημένο υποσύνολο χρηστών (~37.390). Και οι τέσσερις συμμετέχουν σε κάθε γύρο εκπαίδευσης. Το σενάριο αυτό προσφέρει μια ενδιάμεση λύση, μοντελοποιώντας την συλλογή των δεδομένων σε μικρότερους τοπικούς servers σε σχέση με έναν κεντρικό.
- **Pseudo-cross-device με πλήρη δεδομένα:** Μια πρακτικά εφικτή προσέγγιση του cross-device περιβάλλοντος: οι 149.558 χρήστες κατανέμονται σε 2.000 clients (~75 χρήστες ο καθένας), με πλήρη συμμετοχή ανά γύρο. Το σενάριο διατηρεί την χρήση όλων των δεδομένων, θυσιάζοντας ωστόσο την ιδιότητα «ένας χρήστης ανά client» του πραγματικού cross-device, γι' αυτό και χαρακτηρίζεται «pseudo-cross-device».
- **Πραγματικό cross-device (ένας χρήστης ανά client):** Η πιο πιστή αναπαράσταση του cross-device περιβάλλοντος: το σύνολο υποδειγματοληπτείται σε 25.000 χρήστες, καθένας από τους οποίους αποτελεί ξεχωριστό client (μη-IIID γράφος ενός και μόνο χρήστη). Σε κάθε γύρο συμμετέχει μόνο ένα υποσύνολο (~5.000, δηλαδή 20%) των clients, όπως συμβαίνει σε πραγματικά δίκτυα εκατομμυρίων συσκευών. Είναι το πιο απαιτητικό σενάριο, καθώς συνδυάζει έντονη ετερογένεια (client drift) με ελάχιστα τοπικά δεδομένα ανά client.

Σενάριο	Clients	Χρήστες/client	Συμμετοχή/γύρο	Δεδομένα
Centralized	1	149.558	1 (100%)	πλήρη
Cross-silo	4	~37.390	4 (100%)	πλήρη
Pseudo-cross-device	2.000	~75	2.000 (100%)	πλήρη
True cross-device	25.000	1	~5.000 (20%)	25.000 χρ.

Πίνακας 5.4: Τα τέσσερα σενάρια ενορχήστρωσης. Μόνο το true cross-device σενάριο υποδειγματοληπτεί το dataset.



Σχήμα 5.3: Τα τέσσερα σενάρια ενορχήστρωσης: centralized (πάνω αριστερά), cross-silo (πάνω δεξιά), pseudo-cross-device (κάτω αριστερά) και true cross-device (κάτω δεξιά). Σε κάθε σενάριο, το πλήθος των γράφων χρηστών που ανήκει σε κάθε client μειώνεται ολοένα και περισσότερο, δημιουργώντας ένα ολοένα και πιο federated περιβάλλον.

5.4 Μετρικές και πρωτόκολλα αξιολόγησης

Η αξιολόγηση όλων των μοντέλων γίνεται με ενιαία διαδικασία τύπου leave-one-out, ταυτόσημη με εκείνη που χρησιμοποιείται κατά την εκπαίδευση, ώστε τα δύο στάδια να μην αποκλίνουν. Για κάθε χρήστη του test set αφαιρείται μία ακμή (τριπλέτα «συσκευή-κανόνας-συσκευή»), ενώ οι υπόλοιπες αποτελούν το context που τροφοδοτεί το message passing του GNN. Στην συνέχεια το μοντέλο βαθμολογεί την αφαιρεθείσα ακμή έναντι ολόκληρου του χώρου υποψηφίων του γράφου του χρήστη, όλων δηλαδή των δυνατών permutations των συσκευών που απομένουν επί των 552 τύπων κανόνων, αφού πρώτα αποκλειστούν οι υπόλοιπες γνωστές ακμές. Η θέση (rank) της σωστής τριπλέτας προκύπτει ως το πλήθος των υποψηφίων με αυστηρά υψηλότερη βαθμολογία, συν ένα. Πρόκειται για ένα ιδιαίτερα απαιτητικό πρωτόκολλο, καθώς ο χώρος υποψηφίων ανά χρήστη φτάνει σε τάξη μεγέθους δεκάδων χιλιάδων.

5.4.1 Μετρικές

Ως κύρια μετρική χρησιμοποιείται το Mean Reciprocal Rank (MRR):

$$\text{MRR} = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i}$$

όπου Q το σύνολο των ακμών που αφαιρέθηκαν και rank_i το rank της σωστής τριπλέτας για την ακμή i . Το MRR κυμαίνεται στο διάστημα $(0, 1]$ και ανταμείβει την τοποθέτηση της σωστής πρόβλεψης κοντά στην κορυφή της λίστας.

Συμπληρωματικά αναφέρεται η μετρική HitRate@N: το ποσοστό των ακμών για τις οποίες η σωστή τριπλέτα εμφανίζεται εντός των N πρώτων θέσεων.

5.4.2 Πρωτόκολλα αξιολόγησης

Τα αποτελέσματα εξετάζονται κάτω από δύο πρωτόκολλα, τα οποία αντανακλούν δύο διαφορετικές φιλοσοφίες αξιολόγησης. Η διαφοροποίηση αυτή προκύπτει από το γεγονός ότι η υλοποίηση της δεύτερης θέσης αξιολογεί τον εαυτό της σε ένα λιγότερο αυστηρό, αλλά και λιγότερο ουσιαστικό πλαίσιο.

- **Πλήρες leave-one-out (πρωτόκολλο της εργασίας):** Όλες οι ακμές κάθε χρήστη του test set αφαιρούνται και βαθμολογούνται με τη σειρά, χωρίς όριο στο rank. Πρόκειται για το αυστηρότερο και πιο ειλικρινές μέτρο γενίκευσης γιατί

αξιολογεί σε συνθήκες cold-start, με χρήστες και συσκευές που δεν εμφανίστηκαν ποτέ κατά την εκπαίδευση (Ενότητα 5.2.4).

- **Πρωτόκολλο δεύτερης θέσης:** Αφαιρείται μία μόνο ακμή ανά χρήστη, επιλεγμένη ντετερμινιστικά μέσω seed, από το 10% split του train set, και το MRR μηδενίζεται πέραν της 50ής θέσης (MRR@50), υπό την βάση ότι οι συνεισφορές του είναι μηδαμινές.

Οι διαφοροποιήσεις αυτές έχουν διπλό αντίκτυπο στο πλαίσιο αξιολόγησης: Αφενός, η αξιολόγηση στο 10% split του train set αντί για το test set είναι ένα ευκολότερο εγχείρημα, καθώς τα δεδομένα ακολουθούν την ίδια κατανομή με αυτά στα οποία το μοντέλο εκπαιδεύτηκε (in-distribution), και δεν είναι απόλυτα cold-start. Αφετέρου, το γεγονός ότι η αξιολόγηση γίνεται μόνο σε μία, τυχαία επιλεγμένη ακμή κάθε χρήστη και όχι στο σύνολο των ακμών του, την καθιστά μεν σαφώς πιο βιώσιμη υπολογιστικά, αφού δεν εξετάζονται όλα τα πιθανά permutations, αλλά ταυτόχρονα και επιρρεπή στην τυχαιοκρατική φύση της επιλογής ακμής: μπορεί να αφαιρεθεί μία «εύκολη» ακμή από έναν χρήστη, που θα οδηγήσει σε υψηλό rank, ή μία «δύσκολη», που θα υποβαθμίσει το συνολικό αποτέλεσμα. Η εξέταση στο σύνολο των ακμών επιτρέπει την απόλυτα reproducible αξιολόγηση του μοντέλου, ενώ η επιλογή χρηστών από το test set την κάνει ειλικρινή.

Στους πίνακες αποτελεσμάτων, τα δύο πρωτόκολλα συμβολίζονται ως **full** (πλήρες leave-one-out στο test set, πρωτόκολλο εργασίας) και **2nd pl.** (πρωτόκολλο δεύτερης θέσης) αντίστοιχα.

5.5 Αποτελέσματα

Στην παρούσα Ενότητα συγκεντρώνονται τα αποτελέσματα των τεσσάρων εκδόσεων μοντέλων (2ης θέσης, v1, v2 και v3) υπό τα τέσσερα σενάρια ενορχήστρωσης. Ο Πίνακας 5.5 συνοψίζει τα αποτελέσματα των πειραμάτων, με κάθε κελί να αναφέρει το MRR υπό τα δύο πρωτόκολλα (full / 2nd pl.).

Οι παρατηρήσεις που προκύπτουν είναι οι εξής:

- **Η αρχιτεκτονική βελτιώνεται:** Η απλούστερη μέθοδος επίλυσης του προβλήματος είναι η v1, καθώς δεν λαμβάνει υπόψιν τους τύπους των ακμών (Ενότητα 4.2.2). Ο Πίνακας 5.5 καταδεικνύει ότι η απόδοση αυτού του μοντέλου είναι η χειρότερη όλων των πειραμάτων (0,1505 / 0,1445 / 0,0649 / 0,0733), και πε-

Σενάριο	2η θέση (full / 2nd pl.)	v1 (full / 2nd pl.)	v2 (full / 2nd pl.)	v3 (full / 2nd pl.)
Centralized	0,2916 / 0,3487	0,1505 / 0,1999	0,3058 / 0,3574	0,4997 / 0,4956
Cross-silo	---	0,1445 / 0,1978	0,2950 / 0,3489	0,4598 / 0,4725
Pseudo-cross-device	---	0,0649 / 0,0674	0,3645 / 0,3287	0,4087 / 0,4127
True cross-device	---	0,0733 / 0,0885	0,3791 / 0,4257*	0,1981 / 0,1716

Πίνακας 5.5: Συγκεντρωτικός πίνακας αποτελεσμάτων: MRR ανά έκδοση μοντέλου και σενάριο ενορχήστρωσης, υπό τα δύο πρωτόκολλα (full / 2nd pl.). Η στήλη της 2ης θέσης αφορά μόνο κεντριοποιημένη εκπαίδευση, καθώς η υλοποίησή της δεν έγινε σε federated περιβάλλον. Ο δείκτης * σημειώνει ότι η τιμή προέρχεται από μη συγκλίνουσα, ασταθή εκπαίδευση: αποτελεί το βέλτιστο κατά validation μοντέλο και εμφανίζει μεγάλη διακύμανση μεταξύ επαναλήψεων (βλ. [Σχήμα 5.7](#)).


ρίπου η μισή του αμέσως επόμενου μοντέλου (0,2916), αυτού της v2 και της 2ης θέσης. Οι υλοποιήσεις αυτές εισάγουν πανομοιότυπα μοντέλα ([Ενότητα 4.3](#)) και φαίνεται πράγματι να καταλήγουν σε παρόμοια απόδοση. Τέλος, οι αρχιτεκτονικές βελτιώσεις της v3 ([Ενότητα 4.4](#)) φαίνεται να έχουν πραγματικό αντίκτυπο στην συνολική απόδοση, με μία αύξηση της τάξης του 71% στο centralized σενάριο full LOO (0,4997). Επιβεβαιώνεται λοιπόν η θεωρητική διατύπωση ότι ο σχεδιασμός μιας αρχιτεκτονικής εξειδικευμένης στο πρόβλημα που καλείται να επιλύσει συμβάλλει σημαντικά στην αποτελεσματικότητα της εκπαίδευσης.

- **Το κόστος του federation:** Η μελέτη των διαφορετικών σεναρίων ενορχήστρωσης για την v3 αποκαλύπτει ότι υπάρχει ένα υπολογίσιμο αλλά ελεγχόμενο κόστος στην αποδοτικότητα των μοντέλων όσο εισάγεται federation (0,4997 στο centralized σενάριο → 0,4087 στο pseudo-cross-device). Η κατανομή των δεδομένων σε περισσότερους clients με τοπική εκπαίδευση κοστίζει σε επίδοση, ωστόσο εξασφαλίζει όλο και μεγαλύτερη προστασία της ιδιωτικότητας των χρηστών. Εάν συμπεριληφθούν στην μελέτη και οι υπόλοιπες εκδόσεις μοντέλων, το συμπέρασμα για την επιρροή ή μη του federation στην απόδοση δεν είναι ξεκάθαρο.
- **Η αστάθεια του true cross-device σεναρίου:** Όπως είναι φανερό στο [Σχήμα 5.7](#), η σύγκλιση του μοντέλου σε ένα εξ ολοκλήρου cross-device περιβάλλον είναι δύσκολη χωρίς την εισαγωγή επιπλέον διορθωτικών παραμέτρων και τον έλεγχο


της συνεισφοράς κάθε τοπικού μοντέλου. Η απλούστερη έκδοση v2 φαίνεται να έχει υψηλότερες επιδόσεις από την πιο εξειδικευμένη v3, γεγονός που μπορεί να αποδοθεί εν μέρει στην έλλειψη context εκπαίδευσης που απαιτούν οι μηχανισμοί της v3. Παρουσιάζει ωστόσο και μεγαλύτερη αστάθεια σε σχέση με τις v1 και v3, ωστόσο αυτό πιθανώς οφείλεται στις επιλογές των seed για το συγκεκριμένο πείραμα. Για το cross-device σενάριο διενεργήθηκαν επαναληπτικά πειράματα, τα οποία ωστόσο ήταν εξίσου ασταθή με αυτά που παρουσιάζονται εδώ, και δεν κατέληξαν σε συγκλινόν μοντέλο.

5.5.1 Καμπύλες σύγκλισης


Οι καμπύλες σύγκλισης ανά γύρο εκπαίδευσης των τριών εκδόσεων σε καθένα από τα τέσσερα σενάρια ενορχήστρωσης, παρουσιάζονται στα Σχήματα 5.4–5.7, ενώ το Σχήμα 5.8 συγκρίνει την v3 και στα τέσσερα. Κάθε σχήμα δείχνει τέσσερις καμπύλες ανά γύρο: MRR, HitRate@10, σφάλμα εκπαίδευσης (train loss) και σφάλμα στο σύνολο cold-start (test loss), ενώ η κατακόρυφη διακεκομμένη γραμμή σημειώνει τον γύρο του βέλτιστου μοντέλου που βρέθηκε σε κάθε εκπαίδευση, το οποίο επιλέγεται με κριτήριο τη βέλτιστη MRR στο validation. Οι μετρικές MRR/HitRate@10 αφορούν single-edge αξιολόγηση ανά γύρο στο test set και όχι το τελικό cold-start MRR του Πίνακα 5.5 και χρησιμεύουν για τη μελέτη της σύγκλισης και της σχετικής κατάταξης, όχι των απόλυτων τιμών. Τα αποτελέσματα του Πίνακα 5.5 λήφθηκαν από τα βέλτιστα μοντέλα των διακεκομμένων γραμμών στο validation set.




Σχήμα 5.4: Σύγκλιση των τριών εκδόσεων στο centralized σενάριο.




Σχήμα 5.5: Σύγκλιση των τριών εκδόσεων στο cross-silo σενάριο.



Σχήμα 5.6: Σύγκλιση των τριών εκδόσεων στο σενάριο pseudo-cross-device με πλήρη δεδομένα.



Σχήμα 5.7: Σύγκριση των τριών εκδόσεων στο σενάριο true cross-device. Είναι εμφανής η έντονη αστάθεια των καμπυλών, ιδιαίτερα της v2.



Σχήμα 5.8: Σύγκλιση της έκδοσης v3 στα τέσσερα σενάρια ενορχήστρωσης: centralized, cross-silo, pseudo-cross-device και true cross-device.

5.5.2 Ablation studies

Η τελική σύνθεση της έκδοσης v3 προέκυψε από συστηματικά ablation studies σε μικρότερη κλίμακα (centralized, 10.000 χρήστες, 30 γύροι), οι οποίες απομονώνουν τη συνεισφορά κάθε συνιστώσας. Ο Πίνακας 5.6 παρουσιάζει τα αποτελέσματα.

Διαμόρφωση	full	2nd pl.
MLP + BCE (v2)	0,3050	0,3066
MLP + InfoNCE (K=64)	0,2545	0,3338
MLP + BPR (K=64)	0,2466	0,3336
MLP + InfoNCE + hard 50%	0,2732	0,3527
MLP + InfoNCE + hard 100%	0,2029	0,2720
ComplEx + BCE	0,3326	0,2807
DistMult + BCE	0,2969	0,2550
SAGE + ComplEx + InfoNCE + hard 50%	0,3388	0,3717
CompGCN + ComplEx + InfoNCE + hard 50% (v3)	0,4582	0,4369

Πίνακας 5.6: Ablation studies σε μικρή κλίμακα testing (centralized, 10.000 χρήστες, 30 γύροι). Κάθε γραμμή μεταβάλλει μία συνιστώσα ως προς την τελική σύνθεση.

Κατά την διαδικασία του ablation, πραγματοποιήθηκαν πειραματισμοί με συνδυασμούς των προαναφερθέντων αρχιτεκτονικών (MLP και SAGE – Ενότητα 4.2.2, BCE – Ενότητα 3.4.1, InfoNCE και hard negatives – Ενότητα 4.4.3, ComplEx – Ενότητα 4.4.2), αλλά και με τις επιπλέον προσθήκες των BPR και DistMult.





Η BPR (Bayesian Personalized Ranking) [62] είναι μια συνάρτηση σφάλματος που αξιολογεί ζεύγη ακμών: στόχος της είναι να ταξινομήσει μία θετική ακμή πάνω από μία αρνητική. Υπενθυμίζεται ότι η BCE αξιολογεί μεμονωμένες ακμές (στόχος της δηλαδή είναι να ικανοποιήσει όσο το δυνατόν περισσότερες θετικές ακμές), ενώ η InfoNCE είναι μία συνάρτηση που αξιολογεί λίστα ακμών (στόχος της δηλαδή είναι να ταξινομήσει μία θετική ακμή πάνω από K αρνητικές). Η BPR επομένως αποτελεί μία ενδιαμέση λύση των δύο και αξιολογήθηκε πριν υλοποιηθεί η InfoNCE, ώστε να μελετηθεί αν μία αλλαγή στην συνάρτηση σφάλματος μπορεί να οδηγήσει το μοντέλο σε καλύτερα αποτελέσματα.

Το DistMult [54] είναι ένας διγραμμικός embedding decoder με διαγώνιο relation matrix. Αποτελεί relational decoder, όπως το ComplEx, με την διαφορά ότι βαθμο-

λογεί σε πραγματικό διανυσματικό χώρο. Αυτός μάλιστα είναι και ο κυριότερος περιορισμός του, διότι δεν μπορεί να μοντελοποιήσει ασύμμετρες σχέσεις όπως ο μιγαδικός χώρος του ComplEx (Σχήμα 5.9). Υπό αυτή την έννοια, το ComplEx αποτελεί γενίκευση του DistMult. Το DistMult λοιπόν αξιολογήθηκε ως ένα πρώτο βήμα στην κατεύθυνση των relational decoders.

Σε γενικές γραμμές, τα ablation studies αναδεικνύουν τα εξής μοτίβα:

- **Alignment πρωτοκόλλου-συνάρτησης σφάλματος:** Οι BPR και InfoNCE είναι συναρτήσεις κατάταξης (έχουν στόχο να τοποθετήσουν την θετική ακμή πάνω από τις αρνητικές), ενώ η BCE όχι (απλώς αξιολογεί θετικές ακμές). Για τον λόγο αυτό, οι πρώτες φαίνεται να βελτιώνουν την απόδοση του μοντέλου στο σενάριο 2nd pl., το οποίο αφαιρεί μόνο μία ακμή και την αξιολογεί (0,338 και 0,336 έναντι 0,3066 της BCE), ενώ η τελευταία κρατά υψηλές τις επιδόσεις στο σενάριο full leave-one-out, όπου αξιολογούνται όλες οι ακμές (0,3050 έναντι 0,2545 και 0,2466 αντίστοιχα). Η επιλογή λοιπόν μίας συνάρτησης σφάλματος εξαρτάται από το σενάριο αξιολόγησης του μοντέλου.
- **Ποσοστό hard negatives:** Η εισαγωγή hard negatives (Ενότητα 4.4.3) στην εκπαίδευση του μοντέλου φαίνεται να έχει θετικά αποτελέσματα (+2% έναντι απλού InfoNCE), όμως σε ακραία αναλογία φαίνεται ότι βλάπτουν την εκπαίδευση (-5% έναντι απλού InfoNCE). Η επιλογή της μερικής εισαγωγής hard negatives θεωρείται βέλτιστη.
- **ComplEx > DistMult:** Η υπόθεση ότι το ComplEx είναι καταλληλότερο για την επίλυση του παρόντος προβλήματος λόγω της δυνατότητάς του να αναπαριστά ασύμμετρες σχέσεις επιβεβαιώνεται. Το ComplEx επικρατεί του DistMult και στα δύο σενάρια (0,3326 vs 0,2969 και 0,2807 vs 0,2550).
- **Η επίδραση του CompGCN:** Η αντικατάσταση του GraphSAGE από το CompGCN επιφέρει την μεγαλύτερη βελτίωση στην επίδοση σε σχέση με όλες τις άλλες τροποποιήσεις μαζί (+12% στο σενάριο full LOO). Το εύρημα αυτό επιβεβαιώνεται και από το μεμονωμένο ablation του Πίνακα 5.7.
- **Η λύση βρίσκεται στον συνδυασμό μοντέλων:** Καμία λύση δεν δίνει καλύτερες επιδόσεις και στα δύο σενάρια από μόνη της. Η μόνη λύση που πετυχαίνει κάτι τέτοιο είναι ο συνδυασμός μηχανισμών (CompGCN + ComplEx + InfoNCE + hard-50%). Αυτό σηματοδοτεί ότι οι τροποποιήσεις αυτές δεν δρουν αθροιστικά, αλλά συνεργιστικά.



Σχήμα 5.9: Γιατί ο decoder DistMult δεν μπορεί να αναπαραστήσει κατευθυνόμενες σχέσεις, ενώ ο ComplEx μπορεί. **DistMult (πάνω, πραγματικός χώρος):** το score $\langle h, r, t \rangle$ είναι ένα απλό γινόμενο τριών πραγματικών αριθμών, οπότε η εναλλαγή των ρόλων h και t αφήνει το αποτέλεσμα αμετάβλητο (-6 και στις δύο διατάξεις), λόγω της αντιμεταθετικής ιδιότητας του πολλαπλασιασμού ($a \cdot b = b \cdot a$). Η σχέση είναι αναγκαστικά συμμετρική (δεν μπορεί να διακριθεί ο κανόνας « $h \rightarrow t$ » από τον « $t \rightarrow h$ »). **ComplEx (κάτω, μιγαδικό επίπεδο):** Για τον κανόνα « $h \rightarrow t$ » (αριστερά) το score $\text{Re}(\langle h, r, \bar{t} \rangle) = 3$ συζυγίζει το tail, ενώ για τον κανόνα « $t \rightarrow h$ » η συζυγία μεταφέρεται από το t στο h και αλλάζει το score σε $\text{Re}(\langle t, r, \bar{h} \rangle) = -3$: είναι δηλαδή δυνατή η διάκριση του κανόνα « $h \rightarrow t$ » από τον « $t \rightarrow h$ ».

Απομόνωση της συνεισφοράς του CompGCN: Για να απομονωθεί η συνεισφορά ειδικά του CompGCN, εκτελέστηκε σε πλήρη κλίμακα η έκδοση v3 με αντικατάσταση του GraphSAGE (διατηρώντας ComplEx, InfoNCE και hard negatives). Ο Πίνακας 5.7 δείχνει ότι το CompGCN προσθέτει σημαντική βελτίωση σε όλα τα σενάρια: για παράδειγμα, στο centralized, από 0,3627 (GraphSAGE) σε 0,4997 (CompGCN) υπό το πρωτόκολλο full LOO.

Σενάριο	SAGE + ComplEx + InfoNCE (full / 2nd pl.)	v3 (CompGCN + ComplEx + InfoNCE) (full / 2nd pl.)
Centralized	0,3627 / 0,4217	0,4997 / 0,4956
Cross-silo	0,3621 / 0,4293	0,4598 / 0,4725
Pseudo-cross-device	0,3220 / 0,3658	0,4087 / 0,4127

Πίνακας 5.7: Επίδραση της αντικατάστασης του GraphSAGE με CompGCN (σε πλήρη κλίμακα, με σταθερά τα υπόλοιπα στοιχεία της v3).

Κεφάλαιο 6

Συμπεράσματα

6.1 Σύνοψη

Η παρούσα εργασία μελέτησε το πρόβλημα της σύστασης κανόνων IoT σε ομοσπονδιακό πλαίσιο, με αφετηρία τον διαγωνισμό της Wyze και την υλοποίηση της δεύτερης θέσης. Ολόκληρη η πειραματική διαδικασία στηρίχθηκε σε ένα ενιαίο πλαίσιο προσομοίωσης, ικανό να εκτελέσει το ίδιο ακριβώς μοντέλο κάτω από διαφορετικούς τύπους ενορχήστρωσης μεταβάλλοντας μόνο τις παραμέτρους της κατανομής των δεδομένων. Πάνω σε αυτό αναπτύχθηκαν τρεις διαδοχικές εκδόσεις μοντέλου: ένα απλό baseline με GraphSAGE encoder (v1), μια έκδοση εμπλουτισμένη με τον τύπο των ακμών (v2) και, τέλος, ένα relational μοντέλο που συνδυάζει τον CompGCN encoder, τον ComplEx decoder και τη συνάρτηση σφάλματος InfoNCE με hard negatives (v3). Κάθε έκδοση αξιολογήθηκε σε τέσσερα σενάρια ενορχήστρωσης, από την πλήρως centralized εκπαίδευση έως το πλήρως cross-device περιβάλλον, και υπό δύο πρωτόκολλα αξιολόγησης που αποτυπώνουν διαφορετικές φιλοσοφίες αυστηρότητας.

6.2 Βασικά συμπεράσματα

Από την πειραματική μελέτη ([Κεφάλαιο 5](#)) προκύπτουν τρία κύρια συμπεράσματα.

Πρώτον, η αρχιτεκτονική του μοντέλου αποφέρει σημαντικές διαφοροποιήσεις. Στο centralized σενάριο, η έκδοση v3 βελτιώνει το baseline κατά 71% (MRR 0,4997 έναντι 0,2916). Η απομόνωση των συνιστωσών μέσω των ablation studies έδειξε ότι το κέρδος αυτό δεν προέρχεται από κάποιο μεμονωμένο στοιχείο, αλλά από τη συνεργιστική σύνθεσή τους: ο relational encoder (CompGCN) αποδείχθηκε ο καθοριστικότερος παράγοντας, ο κατευθυντικός decoder (ComplEx) υπερίσχυσε των συμμετρικών εναλλακτικών χάρη στη δυνατότητά του να αναπαριστά ασύμμετρες σχέσεις, ενώ η επιλογή της συνάρτησης σφάλματος αποδείχθηκε ότι πρέπει να ευθυγραμμίζεται με το εκάστοτε πρωτόκολλο αξιολόγησης. Καμία από αυτές τις συνιστώσες δεν

επαρκούσε από μόνη της. Μόνο ο συνδυασμός τους ξεπέρασε το baseline και στα δύο πρωτόκολλα ταυτόχρονα.

Δεύτερον, η μετάβαση από την centralized στην federated εκπαίδευση έχει ένα μετρήσιμο αλλά ελεγχόμενο κόστος. Για την έκδοση v3, η επίδοση υποβαθμίζεται σταδιακά καθώς τα δεδομένα κατανέμονται σε ολοένα και περισσότερους clients (0,4997 centralized, 0,4598 cross-silo, 0,4087 pseudo-cross-device), παραμένοντας ωστόσο σαφώς ανώτερη του baseline ακόμη και στο πιο κατανεμημένο εφικτό σενάριο. Η κατανομή των δεδομένων, δηλαδή, δεν ακυρώνει την αξία του μοντέλου, απλώς εισάγει ένα προβλέψιμο τίμημα σε αντάλλαγμα μεγαλύτερης προστασίας της ιδιωτικότητας.

Τρίτον, η βέλτιστη επιλογή μοντέλου εξαρτάται από τον τύπο της ενορχήστρωσης. Στο πιο απαιτητικό σενάριο, το true cross-device περιβάλλον με έναν χρήστη ανά client και μερική συμμετοχή ανά γύρο, η κατάταξη αντιστρέφεται: το ισχυρό relational μοντέλο v3 καταρρέει (0,1981), ενώ η απλούστερη έκδοση v2 αποδεικνύεται ανθεκτικότερη (0,3791). Η παρατήρηση αυτή υπογραμμίζει ότι η πολυπλοκότητα ενός μοντέλου δεν είναι εγγενώς επωφελής: η αξία της εξαρτάται από το διαθέσιμο τοπικό context και τη σταθερότητα των federated ενημερώσεων. Όταν κάθε client διαθέτει ελάχιστη, μη-IID πληροφορία, η πολύπλοκη relational αρχιτεκτονική στερείται τη δομή που χρειάζεται για να μάθει χρήσιμες αναπαραστάσεις και υποχωρεί έναντι μιας απλούστερης λύσης.

6.3 Περιορισμοί

Καθώς το πρόβλημα μελετήθηκε στα πλαίσια μιας διπλωματικής εργασίας, το εύρος που δύναται να καλύψει είναι πεπερασμένο, με αποτέλεσμα να έχει κάποιους περιορισμούς. Πρώτον, όλα τα πειράματα εκτελέστηκαν σε περιβάλλον προσομοίωσης και όχι σε πραγματικές edge συσκευές και ως εκ τούτου ζητήματα όπως η ετερογένεια του hardware, οι καθυστερήσεις δικτύου και οι αποσυνδέσεις clients δεν αποτυπώνονται. Δεύτερον, παρότι η ιδιωτικότητα αποτέλεσε το βασικό κίνητρο, η εργασία περιορίστηκε στη βασική στρατηγική aggregation FedAvg και δεν υλοποίησε μηχανισμούς προστασίας, όπως differential privacy ή secure aggregation. Τρίτον, η αξιολόγηση στηρίχθηκε σε ένα μόνο σύνολο δεδομένων, αυτό που παρείχε η ίδια η εταιρία που διοργάνωσε τον διαγωνισμό. Η γενίκευση των ευρημάτων σε άλλα οικοσυστήματα IoT παραμένει ανοικτό ζήτημα.

6.4 Μελλοντικές επεκτάσεις

Οι παραπάνω περιορισμοί υποδεικνύουν άμεσες κατευθύνσεις για μελλοντική έρευνα. Η ενσωμάτωση μηχανισμών differential privacy και secure aggregation θα έκλεινε τον κύκλο του αρχικού κινήτρου, επιτρέποντας την ποσοτική μέτρηση της αντιστάθμισης μεταξύ ιδιωτικότητας και επιδόσεων. Η κατάρρευση της έκδοσης v3 στο true cross-device σενάριο αποτελεί κίνητρο για την διερεύνηση τεχνικών εξατομίκευσης και ανθεκτικών στρατηγικών συνάθροισης (π.χ. FedProx, FedAdam, SCAFFOLD) που αντιμετωπίζουν το client drift όταν το τοπικό context είναι ελάχιστο. Τέλος, ενδιαφέρουσες αρχιτεκτονικές επεκτάσεις περιλαμβάνουν τον διαχωρισμό των αναπαραστάσεων ανά τύπο συσκευής και κανόνα, την αξιοποίηση πλουσιότερων χαρακτηριστικών κόμβων, καθώς και τη μοντελοποίηση της χρονικής εξέλιξης των αυτοματισμών ενός χρήστη.

Βιβλιογραφία

- [1] Brendan McMahan et al. “Communication-Efficient Learning of Deep Networks from Decentralized Data”. In: *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*. Vol. 54. PMLR. 2017, pp. 1273–1282. arXiv: [1602.05629](https://arxiv.org/abs/1602.05629). URL: <https://proceedings.mlr.press/v54/mcmahan17a.html>. σελ. 1, 8
- [2] *wyzelabs/RuleRecommendation · Datasets at Hugging Face*. URL: <https://huggingface.co/datasets/wyzelabs/RuleRecommendation> (accessed 14/10/2025). σελ. 2, 20, 33
- [3] Francesco Conti. *conti748/wyze-rule-recommendation*. 2024. URL: <https://github.com/conti748/wyze-rule-recommendation> (accessed 05/12/2025). σελ. 2, 28
- [4] Yuhang Yao et al. *FedRule: Federated Rule Recommendation System with Graph Neural Networks*. 2022. DOI: [10.48550/arXiv.2211.06812](https://doi.org/10.48550/arXiv.2211.06812). arXiv: [2211.06812](https://arxiv.org/abs/2211.06812). URL: <http://arxiv.org/abs/2211.06812>. σελ. 3, 20, 22, 25–27
- [5] Yuhang Yao. *yh-yao/FedRule*. URL: <https://github.com/yh-yao/FedRule> (accessed 14/10/2025). σελ. 3, 25
- [6] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, 1997. ISBN: 978-0-07-042807-2. URL: <http://www.cs.cmu.edu/~tom/mlbook.html>. σελ. 4, 5, 7
- [7] Peter Flach, ed. *Machine learning: the art and science of algorithms that make sense of data*. Cambridge University Press, 2012. ISBN: 978-1-107-09639-4. DOI: [10.1017/CBO9780511973000](https://doi.org/10.1017/CBO9780511973000). σελ. 4
- [8] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006. ISBN: 978-0-387-31073-2. URL: <https://www.microsoft.com/en-us/research/publication/pattern-recognition-machine-learning/>. σελ. 4, 5
- [9] Donald Michie, ed. *Machine learning, neural and statistical classification*. 1. publ., 2. [print.] Ellis Horwood series in artificial intelligence. Ellis Horwood, 1995. ISBN: 978-0-13-106360-0. σελ. 4
- [10] Warren S. McCulloch and Walter Pitts. “A logical calculus of the ideas immanent in nervous activity”. In: *The Bulletin of Mathematical Biophysics* 5.4 (1943), pp. 115–133. DOI: [10.1007/BF02478259](https://doi.org/10.1007/BF02478259). σελ. 5
- [11] Frank Rosenblatt. “The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain”. In: *Psychological Review* 65.6 (1958), pp. 386–408. DOI: [10.1037/h0042519](https://doi.org/10.1037/h0042519). σελ. 5

- [12] Ian Goodfellow, Yoshua Bengio and Aaron Courville. *Deep Learning*. MIT Press, 2016. URL: <http://www.deeplearningbook.org>. σελ. 5, 27
- [13] Yann LeCun, Yoshua Bengio and Geoffrey Hinton. “Deep learning”. In: *Nature* 521.7553 (2015), pp. 436–444. DOI: [10.1038/nature14539](https://doi.org/10.1038/nature14539). σελ. 6
- [14] Peter Kairouz, H. Brendan McMahan et al. “Advances and Open Problems in Federated Learning”. In: *Foundations and Trends in Machine Learning* 14.1-2 (2021), pp. 1–210. DOI: [10.1561/22000000083](https://doi.org/10.1561/22000000083). arXiv: [1912.04977](https://arxiv.org/abs/1912.04977). σελ. 7, 11
- [15] Luigi Atzori, Antonio Iera and Giacomo Morabito. “The Internet of Things: A survey”. In: *Computer Networks* 54.15 (2010), pp. 2787–2805. DOI: [10.1016/j.comnet.2010.05.010](https://doi.org/10.1016/j.comnet.2010.05.010). σελ. 7
- [16] Qiang Yang et al. “Federated Machine Learning: Concept and Applications”. In: *ACM Transactions on Intelligent Systems and Technology* 10.2 (2019), pp. 1–19. DOI: [10.1145/3298981](https://doi.org/10.1145/3298981). arXiv: [1902.04885](https://arxiv.org/abs/1902.04885). σελ. 8
- [17] Keith Bonawitz et al. “Towards Federated Learning at Scale: System Design”. In: *Proceedings of Machine Learning and Systems (MLSys)*. Vol. 1. 2019, pp. 374–388. arXiv: [1902.01046](https://arxiv.org/abs/1902.01046). σελ. 8
- [18] Tian Li et al. “Federated Learning: Challenges, Methods, and Future Directions”. In: *IEEE Signal Processing Magazine* 37.3 (2020), pp. 50–60. DOI: [10.1109/MSP.2020.2975749](https://doi.org/10.1109/MSP.2020.2975749). arXiv: [1908.07873](https://arxiv.org/abs/1908.07873). σελ. 9, 11
- [19] Sai Praneeth Karimireddy et al. “SCAFFOLD: Stochastic Controlled Averaging for Federated Learning”. In: *Proceedings of the 37th International Conference on Machine Learning (ICML)*. Vol. 119. PMLR. 2020, pp. 5132–5143. arXiv: [1910.06378](https://arxiv.org/abs/1910.06378). URL: <https://proceedings.mlr.press/v119/karimireddy20a.html>. σελ. 11, 24
- [20] Robin J. Wilson. *Introduction to Graph Theory*. 4th ed. Addison Wesley, 1996. ISBN: 978-0-582-24993-6. σελ. 12, 13
- [21] Franco Scarselli et al. “The Graph Neural Network Model”. In: *IEEE Transactions on Neural Networks* 20.1 (2009), pp. 61–80. DOI: [10.1109/TNN.2008.2005605](https://doi.org/10.1109/TNN.2008.2005605). σελ. 14
- [22] Aditya Grover and Jure Leskovec. “node2vec: Scalable Feature Learning for Networks”. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pp. 855–864. DOI: [10.1145/2939672.2939754](https://doi.org/10.1145/2939672.2939754). arXiv: [1607.00653](https://arxiv.org/abs/1607.00653). σελ. 14
- [23] Bryan Perozzi, Rami Al-Rfou and Steven Skiena. “DeepWalk: Online Learning of Social Representations”. In: *Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2014, pp. 701–710. DOI: [10.1145/2623330.2623732](https://doi.org/10.1145/2623330.2623732). arXiv: [1403.6652](https://arxiv.org/abs/1403.6652). σελ. 14

- [24] Benjamin Sanchez-Lengeling et al. “A Gentle Introduction to Graph Neural Networks”. In: *Distill* (2021). DOI: [10.23915/distill.00033](https://doi.org/10.23915/distill.00033). URL: <https://distill.pub/2021/gnn-intro>. σελ. 15, 16, 18
- [25] Justin Gilmer et al. “Neural Message Passing for Quantum Chemistry”. In: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. Vol. 70. PMLR. 2017, pp. 1263–1272. arXiv: [1704.01212](https://arxiv.org/abs/1704.01212). URL: <https://proceedings.mlr.press/v70/gilmer17a.html>. σελ. 14
- [26] Thomas N. Kipf and Max Welling. “Semi-Supervised Classification with Graph Convolutional Networks”. In: *International Conference on Learning Representations (ICLR)*. 2017. arXiv: [1609.02907](https://arxiv.org/abs/1609.02907). URL: <https://arxiv.org/abs/1609.02907>. σελ. 15, 26
- [27] Petar Veličković et al. “Graph Attention Networks”. In: *International Conference on Learning Representations (ICLR)*. 2018. arXiv: [1710.10903](https://arxiv.org/abs/1710.10903). URL: <https://arxiv.org/abs/1710.10903>. σελ. 15, 26
- [28] William L. Hamilton, Rex Ying and Jure Leskovec. “Inductive Representation Learning on Large Graphs”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 30. 2017. arXiv: [1706.02216](https://arxiv.org/abs/1706.02216). URL: <https://arxiv.org/abs/1706.02216>. σελ. 15–17, 26, 36
- [29] Qimai Li, Zhichao Han and Xiao-Ming Wu. “Deeper Insights into Graph Convolutional Networks for Semi-Supervised Learning”. In: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 32. 2018. arXiv: [1801.07606](https://arxiv.org/abs/1801.07606). URL: <https://arxiv.org/abs/1801.07606>. σελ. 16
- [30] Francesco Ricci et al., eds. *Recommender Systems Handbook*. Springer, 2011. DOI: [10.1007/978-0-387-85820-3](https://doi.org/10.1007/978-0-387-85820-3). σελ. 17
- [31] Gediminas Adomavicius and Alexander Tuzhilin. “Toward the Next Generation of Recommender Systems: A Survey of the State-of-the-Art and Possible Extensions”. In: *IEEE Transactions on Knowledge and Data Engineering* 17.6 (2005), pp. 734–749. DOI: [10.1109/TKDE.2005.99](https://doi.org/10.1109/TKDE.2005.99). σελ. 19
- [32] Yehuda Koren, Robert Bell and Chris Volinsky. “Matrix Factorization Techniques for Recommender Systems”. In: *Computer* 42.8 (2009), pp. 30–37. DOI: [10.1109/MC.2009.263](https://doi.org/10.1109/MC.2009.263). σελ. 21
- [33] Taylor Soper. *Wyze data leak: Key takeaways from server mistake that exposed information from 2.4M customers*. GeekWire. 2019. URL: <https://www.geekwire.com/2019/wyze-data-leak-key-takeaways-server-mistake-exposed-information-2-4m-customers/> (accessed 21/04/2026). σελ. 22

- [34] Haibo He and Edwardo A. Garcia. “Learning from Imbalanced Data”. In: *IEEE Transactions on Knowledge and Data Engineering* 21.9 (2009), pp. 1263–1284. DOI: [10.1109/TKDE.2008.239](https://doi.org/10.1109/TKDE.2008.239). σελ. 23
- [35] Farzin Haddadpour et al. “Federated Learning with Compression: Unified Analysis and Sharp Guarantees”. In: *Proceedings of the 24th International Conference on Artificial Intelligence and Statistics (AISTATS)*. Vol. 130. PMLR. 2021, pp. 2350–2358. arXiv: [2007.01154](https://arxiv.org/abs/2007.01154). URL: <https://proceedings.mlr.press/v130/haddadpour21a.html>. σελ. 24
- [36] Minjie Wang et al. “Deep Graph Library: A Graph-Centric, Highly-Performant Package for Graph Neural Networks”. In: *arXiv preprint arXiv:1909.01315* (2019). arXiv: [1909.01315](https://arxiv.org/abs/1909.01315). URL: <https://arxiv.org/abs/1909.01315>. σελ. 25
- [37] *DGL: Deep Graph Library*. URL: <https://github.com/dmlc/dgl> (accessed 28/11/2025). σελ. 25
- [38] Tom Fawcett. “An Introduction to ROC Analysis”. In: *Pattern Recognition Letters* 27.8 (2006), pp. 861–874. DOI: [10.1016/j.patrec.2005.10.010](https://doi.org/10.1016/j.patrec.2005.10.010). σελ. 27
- [39] Antoine Bordes et al. “Translating Embeddings for Modeling Multi-relational Data”. In: *Advances in Neural Information Processing Systems*. Vol. 26. 2013, pp. 2787–2795. URL: https://proceedings.neurips.cc/paper_files/paper/2013/file/1cecc7a77928ca8133fa24680a88d2f9-Paper.pdf. σελ. 27–29
- [40] Matthias Fey and Jan Eric Lenssen. “Fast Graph Representation Learning with PyTorch Geometric”. In: *ICLR Workshop on Representation Learning on Graphs and Manifolds*. 2019. arXiv: [1903.02428](https://arxiv.org/abs/1903.02428). URL: <https://arxiv.org/abs/1903.02428>. σελ. 28, 47
- [41] *PyTorch Geometric*. URL: https://github.com/pyg-team/pytorch_geometric (accessed 28/11/2025). σελ. 28, 47
- [42] Michael Schlichtkrull et al. “Modeling Relational Data with Graph Convolutional Networks”. In: *The Semantic Web (ESWC)*. Vol. 10843. Lecture Notes in Computer Science. 2018, pp. 593–607. DOI: [10.1007/978-3-319-93417-4_38](https://doi.org/10.1007/978-3-319-93417-4_38). arXiv: [1703.06103](https://arxiv.org/abs/1703.06103). σελ. 29
- [43] Wes McKinney. “Data Structures for Statistical Computing in Python”. In: *Proceedings of the 9th Python in Science Conference (SciPy)*. 2010, pp. 56–61. DOI: [10.25080/Majora-92bf1922-00a](https://doi.org/10.25080/Majora-92bf1922-00a). σελ. 29, 48
- [44] *pandas-dev/pandas: Pandas*. URL: <https://github.com/pandas-dev/pandas> (accessed 28/11/2025). σελ. 29, 48
- [45] Sebastian Ruder. “An Overview of Gradient Descent Optimization Algorithms”. In: *arXiv preprint arXiv:1609.04747* (2016). arXiv: [1609.04747](https://arxiv.org/abs/1609.04747). URL: <https://arxiv.org/abs/1609.04747>. σελ. 29

- [46] Nick Craswell. “Mean Reciprocal Rank”. In: *Encyclopedia of Database Systems*. Ed. by Ling Liu and M. Tamer Özsu. Springer, 2009, p. 1703. DOI: [10.1007/978-0-387-39940-9_488](https://doi.org/10.1007/978-0-387-39940-9_488). σελ. 29
- [47] Daniel J. Beutel et al. *Flower: A Friendly Federated Learning Research Framework*. 2020. arXiv: [2007.14390](https://arxiv.org/abs/2007.14390). URL: <https://arxiv.org/abs/2007.14390>. σελ. 32, 47
- [48] *Flower: A Friendly Federated Learning Framework*. URL: <https://github.com/adap/flower> (accessed 20/02/2026). σελ. 32, 47
- [49] Efstratios Politis. *Federated Rule Recommendation on Graphs – Source Code*. 2026. URL: <https://github.com/stratos-politis/fl-graphs>. σελ. 33, 48
- [50] Shikhar Vashishth et al. “Composition-based Multi-Relational Graph Convolutional Networks”. In: *International Conference on Learning Representations (ICLR)*. 2020. arXiv: [1911.03082](https://arxiv.org/abs/1911.03082). URL: <https://arxiv.org/abs/1911.03082>. σελ. 39, 41
- [51] Théo Trouillon et al. “Complex Embeddings for Simple Link Prediction”. In: *Proceedings of the 33rd International Conference on Machine Learning (ICML)*. Vol. 48. PMLR. 2016, pp. 2071–2080. arXiv: [1606.06357](https://arxiv.org/abs/1606.06357). URL: <https://arxiv.org/abs/1606.06357>. σελ. 39, 41
- [52] Aäron van den Oord, Yazhe Li and Oriol Vinyals. “Representation Learning with Contrastive Predictive Coding”. In: *arXiv preprint arXiv:1807.03748* (2018). URL: <https://arxiv.org/abs/1807.03748>. σελ. 39, 41
- [53] Maximilian Nickel et al. “A Review of Relational Machine Learning for Knowledge Graphs”. In: *Proceedings of the IEEE* 104.1 (2016), pp. 11–33. DOI: [10.1109/JPROC.2015.2483592](https://doi.org/10.1109/JPROC.2015.2483592). σελ. 39
- [54] Bishan Yang et al. “Embedding Entities and Relations for Learning and Inference in Knowledge Bases”. In: *International Conference on Learning Representations (ICLR)*. 2015. arXiv: [1412.6575](https://arxiv.org/abs/1412.6575). URL: <https://arxiv.org/abs/1412.6575>. σελ. 41, 64
- [55] Thomas M. Cover and Joy A. Thomas. *Elements of Information Theory*. 2nd ed. Wiley-Interscience, 2006. DOI: [10.1002/047174882X](https://doi.org/10.1002/047174882X). σελ. 41
- [56] Giulia Di Teodoro et al. “A Theoretical Analysis of Recommendation Loss Functions under Negative Sampling”. In: *arXiv preprint arXiv:2411.07770* (2024). URL: <https://arxiv.org/abs/2411.07770>. σελ. 41
- [57] Adam Paszke, Sam Gross, Francisco Massa et al. “PyTorch: An Imperative Style, High-Performance Deep Learning Library”. In: *Advances in Neural Information Processing Systems 32 (NeurIPS)*. 2019. URL: <https://arxiv.org/abs/1912.01703>. σελ. 47
- [58] *PyTorch*. URL: <https://github.com/pytorch/pytorch> (accessed 28/11/2025). σελ. 47

- [59] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt et al. “Array programming with NumPy”. In: *Nature* 585 (2020), pp. 357–362. DOI: [10.1038/s41586-020-2649-2](https://doi.org/10.1038/s41586-020-2649-2). σελ. 48
- [60] *NumPy*. URL: <https://github.com/numpy/numpy> (accessed 28/11/2025). σελ. 48
- [61] *tqdm: A Fast, Extensible Progress Bar for Python and CLI*. URL: <https://github.com/tqdm/tqdm> (accessed 28/11/2025). σελ. 48
- [62] Steffen Rendle et al. “BPR: Bayesian Personalized Ranking from Implicit Feedback”. In: *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence (UAI)*. 2009, pp. 452–461. arXiv: [1205.2618](https://arxiv.org/abs/1205.2618). URL: <https://arxiv.org/abs/1205.2618>. σελ. 64

